

ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI
TRƯỜNG KINH TẾ



KHÓA LUẬN TỐT NGHIỆP
NGÀNH PHÂN TÍCH DỮ LIỆU KINH DOANH

ĐỀ TÀI: DỰ BÁO RỦI RO VỐ NỢ
KHÁCH HÀNG CÁ NHÂN:
TIẾP CẬN MACHINE LEARNING KẾT HỢP
EXPLAINABLE AI TRÊN DỮ LIỆU THẺ TÍN DỤNG

Họ và tên sinh viên : Dương Thị Hồng Ngọc

Mã sinh viên : 2022601391

Lớp - khóa : 2022DHDLKD01 - K17

Giảng viên hướng dẫn : ThS. Trương Hoàng Giang

HÀ NỘI – 2026

ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI
TRƯỜNG KINH TẾ



KHÓA LUẬN TỐT NGHIỆP
NGÀNH PHÂN TÍCH DỮ LIỆU KINH DOANH

ĐỀ TÀI: DỰ BÁO RỦI RO VỐ NỢ
KHÁCH HÀNG CÁ NHÂN:
TIẾP CẬN MACHINE LEARNING KẾT HỢP
EXPLAINABLE AI TRÊN DỮ LIỆU THẺ TÍN DỤNG

Họ và tên sinh viên : Dương Thị Hồng Ngọc

Mã sinh viên : 2022601391

Lớp - khóa : 2022DHDLKD01 - K17

Giảng viên hướng dẫn : ThS. Trương Hoàng Giang

HÀ NỘI – 2026

LỜI CẢM ƠN

Trong quá trình thực hiện khóa luận tốt nghiệp với đề tài “Dự báo rủi ro vỡ nợ khách hàng cá nhân: Tiếp cận Machine Learning kết hợp Explainable AI trên dữ liệu thẻ tín dụng”, em đã nhận được sự quan tâm, hướng dẫn và hỗ trợ từ quý thầy cô, gia đình và bạn bè. Đây là nguồn động viên quan trọng giúp em hoàn thành đề tài này.

Trước hết, em xin gửi lời cảm ơn chân thành tới ThS. Trương Hoàng Giang – giảng viên hướng dẫn của em. Thầy đã tận tình định hướng, góp ý và hỗ trợ em trong quá trình lựa chọn phương pháp nghiên cứu, triển khai nội dung và hoàn thiện khóa luận. Những nhận xét quý báu của thầy đã giúp em nhìn nhận vấn đề rõ ràng hơn và nâng cao chất lượng bài nghiên cứu.

Em cũng xin gửi lời cảm ơn tới các thầy cô trong Khoa Kinh doanh số và Trường Kinh tế – Trường Đại học Công nghiệp Hà Nội đã trang bị cho em kiến thức chuyên môn, kỹ năng phân tích và tư duy nghiên cứu cần thiết trong suốt quá trình học tập.

Bên cạnh đó, em xin bày tỏ lòng biết ơn tới gia đình, bạn bè và những người đã luôn động viên, hỗ trợ và tạo điều kiện để em yên tâm học tập, nghiên cứu.

Mặc dù đã cố gắng trong quá trình thực hiện, khóa luận khó tránh khỏi những hạn chế và thiếu sót. Em rất mong nhận được những ý kiến góp ý từ quý thầy cô để bài nghiên cứu được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Sinh viên thực hiện

Dương Thị Hồng Ngọc

MỤC LỤC

LỜI CẢM ƠN	i
MỤC LỤC.....	ii
DANH MỤC PHỤ LỤC	v
DANH MỤC HÌNH ẢNH	vi
DANH MỤC BẢNG.....	vi
DANH MỤC TỪ VIẾT TẮT.....	vii
LỜI MỞ ĐẦU	1
CHƯƠNG 1 TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LÝ LUẬN.....	4
1.1 Rủi ro tín dụng.....	4
1.1.1 Khái niệm	4
1.1.2 Nguyên nhân gây rủi ro tín dụng	5
1.1.3 Tác động của rủi ro tín dụng đối với ngân hàng	5
1.2 Chấm điểm tín dụng cá nhân.....	6
1.2.1 Khái niệm và vai trò.....	6
1.2.2 Quy trình xây dựng hệ thống	6
1.3 Machine Learning trong chấm điểm tín dụng.....	7
1.3.1 Phân biệt mô hình truyền thống với mô hình học máy.....	7
1.3.2 Các mô hình phổ biến trong dự báo vỡ nợ.....	8
1.4 Explainable AI trong tài chính	10
1.4.1 Khái niệm XAI.....	10
1.4.2 Tầm quan trọng của Explainable AI trong chấm điểm tín dụng	11
1.4.3 Các phương pháp giải thích mô hình (SHAP, Feature Importance) ..	12
1.5 Tổng quan các nghiên cứu liên quan.....	14
1.5.1 Nghiên cứu về Machine Learning trong chấm điểm tín dụng	14
1.5.2 Nghiên cứu về XAI trong chấm điểm tín dụng.....	15
1.5.3 Tổng hợp và phê bình các hướng nghiên cứu.....	16

1.6 Khoảng trống nghiên cứu.....	17
1.7 Khung nghiên cứu đề xuất	18
1.8 Kết luận chương	19
CHƯƠNG 2 DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU	20
2.1 Mô tả dữ liệu	20
2.2 Phân chia dữ liệu và thiết kế tập holdout	21
2.3 Tiền xử lý dữ liệu và xây dựng đặc trưng	22
2.4 Xử lý mất cân bằng, pipeline và kiểm định chéo.....	23
2.5 Xây dựng và tối ưu mô hình.....	24
2.6 Đánh giá mô hình và tối ưu ngưỡng F2	25
2.7 Thiết lập ngưỡng phân nhóm rủi ro	26
2.8 Explainable AI bằng SHAP.....	27
2.9 Kết luận chương	28
CHƯƠNG 3 KẾT QUẢ VÀ THẢO LUẬN	30
3.1 Kết quả và so sánh hiệu suất mô hình.....	30
3.1.1 Kết quả tổng hợp của các mô hình.....	31
3.1.2 Đường cong ROC và Precision–Recall.....	33
3.1.3 Ma trận nhầm lẫn và tác động của ngưỡng tối ưu.....	34
3.1.4 Trả lời câu hỏi nghiên cứu 1.....	35
3.2 Phân tích các biến đóng góp vào dự báo theo SHAP values	37
3.2.1 Tầm quan trọng toàn cục của các biến	38
3.2.2 Hướng đóng góp của các biến qua SHAP summary plot.....	40
3.2.3 Diễn giải kinh tế của các yếu tố rủi ro chính	41
3.2.4 Trả lời câu hỏi nghiên cứu 2.....	42
3.3 Phân tích rủi ro và hỗ trợ quyết định tín dụng	42
3.3.1 Phân nhóm rủi ro dựa trên xác suất vỡ nợ dự báo	43
3.3.2 Bảng hỗ trợ quyết định tín dụng theo nhóm rủi ro.....	44

3.3.3 Giải thích nhóm rủi ro bằng SHAP	45
3.3.4 Minh họa giải thích cấp cá nhân: waterfall plot.....	46
3.3.5 Trả lời câu hỏi nghiên cứu 3.....	47
3.4 Thảo luận tổng hợp.....	48
3.4.1 So sánh với nghiên cứu trước trên bộ dữ liệu UCI	48
3.4.2 Lựa chọn mô hình phân tích chính.....	48
3.4.3 Giới hạn khi diễn giải kết quả.....	49
3.5 Kết luận chương 3	49
CHƯƠNG 4 KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ.....	51
4.1 Kết luận chung	51
4.2 Hàm ý quản trị.....	52
4.2.1 Hàm ý đối với xây dựng mô hình chấm điểm tín dụng	52
4.2.2 Hàm ý đối với thiết lập ngưỡng ra quyết định	53
4.2.3 Hàm ý đối với minh bạch và giải trình mô hình	54
4.2.4 Hàm ý đối với quy trình vận hành tín dụng	55
4.3 Hạn chế của nghiên cứu	56
4.4 Hướng nghiên cứu tiếp theo.....	57
4.5 Kết luận chương	59
TÀI LIỆU THAM KHẢO.....	61
PHỤ LỤC.....	64

DANH MỤC PHỤ LỤC

PHỤ LỤC A. KIỂM ĐỊNH ĐỘ ỔN ĐỊNH HIỆU SUẤT MÔ HÌNH.....	64
PHỤ LỤC B. KIỂM TRA CALIBRATION CỦA XÁC SUẤT DỰ BÁO.....	65
PHỤ LỤC C. CÔNG THỨC XÂY DỰNG ĐẶC TRƯNG.....	66
PHỤ LỤC D. CÔNG THỨC SMOTE VÀ CÁC CHỈ SỐ ĐÁNH GIÁ.....	66
PHỤ LỤC E. MA TRẬN NHẦM LẤN CHI TIẾT	68
PHỤ LỤC F. CẤU HÌNH MÔ HÌNH VÀ THAM SỐ TỐI ƯU.....	69
PHỤ LỤC G. SO SÁNH VỚI NGHIÊN CỨU TRƯỚC	69

DANH MỤC HÌNH ẢNH

Hình 3.1: Đường cong ROC của các mô hình	33
Hình 3.2: Đường cong Precision–Recall của các mô hình	34
Hình 3.3: Top 20 biến quan trọng theo giá trị SHAP của mô hình Random Forest	38
Hình 3.4: SHAP summary plot của mô hình Random Forest.....	40
Hình 3.5: Tỷ lệ vỡ nợ quan sát theo nhóm rủi ro	44
Hình 3.6: Waterfall plot minh họa dự báo cho một hồ sơ khách hàng rủi ro cao	46

DANH MỤC BẢNG

Bảng 2.1: Thiết kế phân chia dữ liệu trong nghiên cứu	22
Bảng 2.2: Các đặc trưng hành vi được xây dựng trong nghiên cứu	22
Bảng 2.3: Quy tắc phân nhóm rủi ro trong nghiên cứu.....	27
Bảng 3.1: Kết quả so sánh hiệu quả dự báo của các mô hình trên tập kiểm tra holdout.....	31
Bảng 3.2: Ma trận nhầm lẫn của các mô hình tại ngưỡng tối ưu.....	35
Bảng 3.3: Phân nhóm rủi ro trên tập kiểm tra holdout.....	43
Bảng 3.4: Bảng hỗ trợ quyết định tín dụng minh họa theo nhóm rủi ro	45

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nghĩa
ML	Machine Learning
AI	Artificial Intelligence
XAI	Explainable Artificial Intelligence
SHAP	SHAPley Additive exPlanations
LR	Logistic Regression
RF	Random Forest
XGB	XGBoost
SVM	Support Vector Machine
ROC-AUC	Area Under ROC Curve
PR-AUC	Area Under Precision–Recall Curve
SMOTE	Synthetic Minority Over-sampling Technique
PD	Probability of Default
LIME	Local Interpretable Model-agnostic Explanations
KS	Kolmogorov–Smirnov Statistic
LGD	Loss Given Default
EAD	Exposure at Default

LỜI MỞ ĐẦU

Trong bối cảnh số hóa tài chính – ngân hàng, hoạt động tín dụng cá nhân ngày càng đóng vai trò quan trọng trong việc mở rộng khả năng tiếp cận tài chính của khách hàng và hỗ trợ tăng trưởng tiêu dùng [1]. Tuy nhiên, sự mở rộng của tín dụng cũng đi kèm với rủi ro khách hàng không thực hiện đúng nghĩa vụ thanh toán. Theo Ủy ban Basel về Giám sát Ngân hàng (2000), rủi ro tín dụng phát sinh khi bên vay hoặc đối tác không thực hiện nghĩa vụ tài chính theo các điều khoản đã cam kết, từ đó gây tổn thất cho tổ chức cho vay [2]. Vì vậy, việc xây dựng các mô hình dự báo rủi ro vỡ nợ có ý nghĩa quan trọng trong quản trị rủi ro tín dụng.

Trong lĩnh vực chấm điểm tín dụng, các mô hình thống kê truyền thống như hồi quy logistic đã được sử dụng rộng rãi nhờ cấu trúc đơn giản và khả năng diễn giải tương đối rõ ràng [3], [4]. Tuy nhiên, các nghiên cứu so sánh trong lĩnh vực chấm điểm tín dụng cho thấy nhiều mô hình học máy, đặc biệt là các phương pháp ensemble và boosting, thường đạt hiệu quả dự báo cạnh tranh hoặc cao hơn so với một số mô hình thống kê truyền thống trên nhiều bộ dữ liệu thực nghiệm [5]. Dù vậy, hiệu quả dự báo cao chưa phải là điều kiện đủ để mô hình được sử dụng trong môi trường tài chính, bởi quyết định tín dụng còn đòi hỏi khả năng minh bạch, kiểm tra và giải trình [6], [7].

Các nghiên cứu về Explainable Artificial Intelligence (XAI) cho thấy các phương pháp giải thích mô hình có vai trò quan trọng trong việc làm rõ cơ sở hình thành dự báo của các mô hình học máy, đặc biệt trong những lĩnh vực có yêu cầu giải trình cao như tài chính – tín dụng [6], [7], [8]. Trong số các phương pháp XAI, SHAP có ưu điểm là cung cấp cách phân bổ đóng góp của từng biến đầu vào dựa trên nền tảng giá trị Shapley, đồng thời hỗ trợ cả phân tích toàn cục và cục bộ [9]. So với các phương pháp giải thích cục bộ như LIME, SHAP phù hợp hơn với mục tiêu của nghiên cứu này vì có thể vừa xác định các biến quan trọng trên toàn bộ mô hình, vừa giải thích dự báo đối với từng hồ sơ khách hàng cụ thể [9], [10].

Tuy nhiên, nhiều nghiên cứu về chấm điểm tín dụng vẫn chủ yếu tập trung vào so sánh hiệu suất dự báo giữa các thuật toán, trong khi việc kết nối kết quả dự

báo với giải thích mô hình và hỗ trợ quyết định tín dụng chưa được trình bày như một quy trình thống nhất [5], [6], [7]. Nói cách khác, khoảng trống không chỉ nằm ở việc lựa chọn mô hình có chỉ số tốt hơn, mà còn ở cách chuyển hóa đầu ra của mô hình thành thông tin có thể giải thích, kiểm tra và sử dụng trong quá trình phân nhóm rủi ro tín dụng. Đây là khoảng trống mà đề tài hướng tới: kết hợp Machine Learning với Explainable AI nhằm xây dựng một quy trình dự báo, giải thích và hỗ trợ quyết định tín dụng trên cùng một khung thực nghiệm.

Từ những vấn đề trên, đề tài “Dự báo rủi ro vỡ nợ khách hàng cá nhân: Tiếp cận Machine Learning kết hợp Explainable AI trên dữ liệu thẻ tín dụng” được thực hiện nhằm xây dựng một quy trình dự báo rủi ro vỡ nợ dựa trên các mô hình học máy, đồng thời sử dụng SHAP để giải thích các yếu tố đóng góp vào kết quả dự báo. Trọng tâm của nghiên cứu không nằm ở việc đề xuất một thuật toán mới, mà ở việc tích hợp các bước dự báo, đánh giá, giải thích và hỗ trợ quyết định tín dụng trong một quy trình thực nghiệm có thể kiểm chứng. Cần nhấn mạnh rằng SHAP trong nghiên cứu này không được sử dụng để chứng minh quan hệ nhân quả giữa các biến và tình trạng vỡ nợ, mà nhằm giải thích cách mô hình sử dụng các đặc trưng đầu vào để hình thành dự báo.

Nghiên cứu hướng tới ba mục tiêu chính. Thứ nhất, so sánh hiệu quả dự báo của Logistic Regression, Random Forest và XGBoost, đồng thời sử dụng Dummy Classifier làm mốc tham chiếu cơ sở. Thứ hai, xác định các biến có đóng góp quan trọng vào dự báo rủi ro vỡ nợ thông qua giá trị SHAP. Thứ ba, chuyển hóa kết quả dự báo và giải thích mô hình thành phân nhóm rủi ro và bảng hỗ trợ quyết định tín dụng nhằm minh họa khả năng ứng dụng trong quản trị rủi ro.

Để đạt được các mục tiêu trên, nghiên cứu tập trung trả lời ba câu hỏi sau:

Câu hỏi nghiên cứu 1: Các mô hình học máy như Random Forest và XGBoost có cải thiện hiệu quả dự báo rủi ro vỡ nợ so với Logistic Regression trong phạm vi bộ dữ liệu nghiên cứu hay không?

Câu hỏi nghiên cứu 2: Những biến nào có đóng góp quan trọng nhất vào dự báo rủi ro vỡ nợ của khách hàng cá nhân khi được phân tích thông qua SHAP?

Câu hỏi nghiên cứu 3: Kết quả từ mô hình Machine Learning kết hợp Explainable AI có thể cung cấp căn cứ minh bạch như thế nào cho quá trình phân nhóm rủi ro và hỗ trợ quyết định tín dụng?

Đối tượng nghiên cứu của đề tài là rủi ro vỡ nợ của khách hàng cá nhân trong hoạt động tín dụng thẻ. Nghiên cứu sử dụng bộ dữ liệu Default of Credit Card Clients Dataset do Yeh và Lien công bố, một bộ dữ liệu được sử dụng phổ biến trong các nghiên cứu về chấm điểm tín dụng và dự báo vỡ nợ [11]. Bộ dữ liệu này được lựa chọn nhằm minh họa quy trình kết hợp giữa Machine Learning và Explainable AI trên một nguồn dữ liệu chuẩn, có khả năng đối chiếu với các nghiên cứu trước. Do dữ liệu phản ánh bối cảnh khách hàng thẻ tín dụng tại Đài Loan, kết quả nghiên cứu không nhằm khẳng định khả năng áp dụng trực tiếp cho Việt Nam mà cần được kiểm định lại nếu triển khai trên dữ liệu thực tế của từng tổ chức tài chính.

Về phương pháp, nghiên cứu sử dụng cách tiếp cận định lượng, kết hợp các kỹ thuật học máy với phương pháp giải thích mô hình. Quy trình nghiên cứu bao gồm tiền xử lý dữ liệu, xây dựng mô hình dự báo, đánh giá hiệu suất, lựa chọn mô hình phân tích chính và giải thích kết quả bằng SHAP. Các kết quả dự báo sau đó được sử dụng để phân nhóm rủi ro và xây dựng bảng hỗ trợ quyết định tín dụng. Nội dung chi tiết về dữ liệu, quy trình xử lý, mô hình, chỉ số đánh giá và phương pháp giải thích được trình bày trong Chương 2.

Khóa luận được kết cấu thành bốn chương. Chương 1 trình bày tổng quan nghiên cứu và cơ sở lý luận về rủi ro tín dụng, chấm điểm tín dụng, Machine Learning và Explainable AI. Chương 2 trình bày dữ liệu và phương pháp nghiên cứu. Chương 3 trình bày kết quả thực nghiệm, phân tích SHAP, phân nhóm rủi ro và thảo luận kết quả. Chương 4 đưa ra kết luận, hàm ý quản trị, hạn chế của nghiên cứu và hướng nghiên cứu tiếp theo.

CHƯƠNG 1 TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LÝ LUẬN

Chương này nhằm xây dựng nền tảng lý luận và tổng quan nghiên cứu cho đề tài dự báo rủi ro tín dụng trong lĩnh vực tài chính – ngân hàng. Trên cơ sở các khái niệm nền tảng, chương tập trung phân tích các phương pháp chấm điểm tín dụng từ truyền thống đến hiện đại, đặc biệt là các kỹ thuật Machine Learning và Explainable Artificial Intelligence (XAI).

Nội dung được tổ chức thành hai phần chính: phần cơ sở lý luận trình bày các khái niệm nền tảng về rủi ro tín dụng, chấm điểm tín dụng, Machine Learning và XAI; phần tổng quan tài liệu tổng hợp và phê bình các hướng nghiên cứu hiện có, từ đó xác định khoảng trống và đề xuất khung nghiên cứu của đề tài.

1.1 Rủi ro tín dụng

1.1.1 Khái niệm

Rủi ro tín dụng (credit risk), hay còn được gọi là rủi ro vỡ nợ, phản ánh khả năng bên vay không thực hiện đầy đủ các nghĩa vụ tài chính theo các điều khoản đã cam kết trong hợp đồng tín dụng. Nói cách khác, đây là mức độ không chắc chắn liên quan đến khả năng thanh toán của khách hàng, có thể dẫn đến tổn thất tài chính cho tổ chức cho vay. Theo định nghĩa của Ủy ban Basel (2000) về Giám sát Ngân hàng, rủi ro tín dụng phát sinh khi một bên vay hoặc đối tác không thực hiện nghĩa vụ theo thỏa thuận, từ đó gây ra tổn thất cho ngân hàng [2].

Trong các nghiên cứu học thuật, rủi ro tín dụng không chỉ được xem xét dưới góc độ vỡ nợ hoàn toàn mà còn bao gồm các dạng rủi ro liên quan đến sự biến động của chất lượng tín dụng. Cụ thể, Bielecki và Rutkowski (2004) cho rằng rủi ro tín dụng có thể được tiếp cận thông qua ba khía cạnh chính: rủi ro vỡ nợ, rủi ro chênh lệch tín dụng và rủi ro suy giảm xếp hạng tín nhiệm [12]. Cách tiếp cận này cho thấy rủi ro tín dụng mang tính đa chiều và chịu ảnh hưởng bởi cả yếu tố thị trường lẫn đặc điểm nội tại của khách hàng.

1.1.2 Nguyên nhân gây rủi ro tín dụng

Rủi ro tín dụng được hình thành từ sự tương tác của nhiều yếu tố khác nhau, có thể được phân thành hai nhóm chính: các yếu tố ngoại sinh và các yếu tố nội sinh.

Các yếu tố ngoại sinh chủ yếu bao gồm những yếu tố liên quan đến môi trường kinh tế vĩ mô. Những biến động như suy thoái kinh tế, lạm phát hoặc thay đổi lãi suất có thể làm suy giảm thu nhập và khả năng trả nợ của khách hàng. Nghiên cứu của Nkusu (2011) chỉ ra rằng sự suy giảm tăng trưởng kinh tế có mối liên hệ chặt chẽ với sự gia tăng tỷ lệ nợ xấu trong hệ thống ngân hàng [13].

Bên cạnh đó, các yếu tố nội sinh phản ánh đặc điểm tài chính của khách hàng và năng lực quản trị của ngân hàng. Các yếu tố như thu nhập không ổn định, lịch sử tín dụng kém hoặc mức độ đòn bẩy tài chính cao làm gia tăng xác suất vỡ nợ. Đồng thời, các hạn chế trong quy trình thẩm định, chính sách tín dụng và quản trị danh mục cũng có thể dẫn đến việc đánh giá sai rủi ro [14].

1.1.3 Tác động của rủi ro tín dụng đối với ngân hàng

Rủi ro tín dụng có ảnh hưởng trực tiếp đến hiệu quả hoạt động và mức độ ổn định tài chính của ngân hàng. Khi khách hàng không thực hiện nghĩa vụ thanh toán, ngân hàng phải chịu tổn thất tài chính do không thu hồi được cả gốc và lãi, đồng thời phải gia tăng chi phí trích lập dự phòng rủi ro, làm suy giảm lợi nhuận [15].

Ngoài ra, rủi ro tín dụng còn ảnh hưởng đến khả năng thanh khoản và an toàn vốn của ngân hàng. Việc gia tăng nợ xấu có thể làm gián đoạn dòng tiền và buộc ngân hàng phải duy trì mức vốn cao hơn theo các chuẩn mực quốc tế như Basel III (2017), từ đó hạn chế khả năng mở rộng tín dụng [16].

Saunders và Cornett (2019) tổng hợp rằng tác động của rủi ro tín dụng không giới hạn ở tổn thất tài chính tức thời mà còn làm suy giảm uy tín thị trường và niềm tin của người gửi tiền trong dài hạn [17].

1.2 Chấm điểm tín dụng cá nhân

1.2.1 Khái niệm và vai trò

Thomas và cộng sự (2017) định nghĩa chấm điểm tín dụng là việc sử dụng các mô hình thống kê để ước lượng xác suất một người vay không thực hiện đầy đủ nghĩa vụ tài chính, dựa trên dữ liệu lịch sử về đặc điểm và hành vi của khách hàng [18]. Về bản chất, bài toán chấm điểm tín dụng thường được xem là một bài toán phân loại nhị phân, trong đó khách hàng được phân vào nhóm có nguy cơ vỡ nợ hoặc nhóm thanh toán đúng hạn. Từ kết quả này, tổ chức tín dụng có thể lượng hóa rủi ro dưới dạng điểm số hoặc nhóm rủi ro để phục vụ quá trình so sánh và ra quyết định. Hand và Henley (1997) lưu ý rằng đây là một trong số ít lĩnh vực mà mô hình thống kê được ứng dụng ở quy mô rất lớn và có tác động tài chính trực tiếp đến hàng triệu khách hàng mỗi năm [3].

Xét theo vòng đời khách hàng, các mô hình chấm điểm tín dụng thường gồm ba loại: chấm điểm hồ sơ vay mới, chấm điểm hành vi (behavioural scoring) và chấm điểm thu hồi nợ (collection scoring). Mỗi loại mô hình phục vụ một mục tiêu khác nhau nhưng đều hướng đến việc tối ưu hóa hiệu quả quản trị rủi ro tín dụng.

Thomas và cộng sự (2017) chỉ ra ba lợi ích vận hành chính của chấm điểm tín dụng: rút ngắn thời gian xét duyệt hồ sơ, giảm chi phí thẩm định thủ công và tăng tính nhất quán trong ra quyết định [18]. Hand và Henley (1997) cũng chỉ ra rằng việc sử dụng các mô hình định lượng có thể làm giảm sai lệch cá nhân trong đánh giá tín dụng, thay vì phụ thuộc hoàn toàn vào phán đoán chủ quan của chuyên viên [3]. Thomas (2009) lưu ý thêm rằng khi hệ thống tín dụng tiêu dùng mở rộng sang phân khúc khách hàng ít lịch sử tín dụng hơn, chấm điểm dựa trên dữ liệu thay thế trở thành công cụ quan trọng để mở rộng tiếp cận tài chính mà không làm tăng tỷ lệ nợ xấu hệ thống [4].

1.2.2 Quy trình xây dựng hệ thống

Quy trình xây dựng hệ thống chấm điểm tín dụng thường bắt đầu từ việc xác định mục tiêu đánh giá rủi ro, trong đó trọng tâm là ước lượng khả năng khách

hàng không thực hiện đúng nghĩa vụ trả nợ trong một khoảng thời gian nhất định. Đây là nền tảng để tổ chức tài chính lựa chọn dữ liệu đầu vào, phương pháp mô hình hóa và tiêu chí đánh giá phù hợp với mục tiêu quản trị rủi ro tín dụng [2].

Tiếp theo, dữ liệu khách hàng được thu thập và xử lý nhằm bảo đảm chất lượng đầu vào. Trong bài toán chấm điểm tín dụng cá nhân, dữ liệu thường bao gồm đặc điểm nhân khẩu học, hạn mức tín dụng, hành vi sử dụng tín dụng và lịch sử thanh toán. Các nhóm thông tin này cũng được phản ánh trong bộ dữ liệu thẻ tín dụng của Yeh và Lien (2009), vốn được sử dụng rộng rãi trong các nghiên cứu về dự báo rủi ro vỡ nợ [11].

Sau khi dữ liệu được xử lý, các biến đầu vào được lựa chọn và biến đổi để phục vụ mô hình dự báo. Ở bước mô hình hóa, các phương pháp truyền thống như hồi quy logistic có thể được sử dụng cùng với các thuật toán học máy hiện đại. Nghiên cứu của Lessmann và cộng sự (2015) cho thấy các thuật toán học máy thường có khả năng cải thiện hiệu quả dự báo trong bài toán chấm điểm tín dụng so với nhiều phương pháp truyền thống [5].

Cuối cùng, mô hình cần được đánh giá trên dữ liệu kiểm định độc lập trước khi được sử dụng để hỗ trợ quyết định tín dụng. Bên cạnh hiệu quả dự báo, khả năng giải thích kết quả cũng là một yêu cầu quan trọng, đặc biệt trong bối cảnh các mô hình học máy thường bị xem là khó diễn giải. Vì vậy, các phương pháp Explainable AI như SHAP có thể được sử dụng để làm rõ vai trò của các biến đầu vào và hỗ trợ giải thích kết quả dự báo ở cả cấp độ tổng thể lẫn từng khách hàng [9], [6].

1.3 Machine Learning trong chấm điểm tín dụng

1.3.1 Phân biệt mô hình truyền thống với mô hình học máy

Sự phát triển của các phương pháp học máy (Machine Learning – ML) đã tạo ra bước tiến quan trọng trong chấm điểm tín dụng, cho phép xây dựng các mô hình dự báo với độ chính xác cao hơn, đặc biệt trong bối cảnh dữ liệu có cấu trúc phức tạp và tồn tại các mối quan hệ phi tuyến [5].

Trong thực tiễn, các phương pháp phân loại rủi ro tín dụng được chia thành hai nhóm chính: mô hình truyền thống và mô hình học máy. Các mô hình truyền thống như hồi quy logistic hay thẻ điểm được sử dụng rộng rãi nhờ tính đơn giản và khả năng diễn giải rõ ràng, phù hợp với các yêu cầu quản lý. Tuy nhiên, các mô hình này thường giả định quan hệ tuyến tính, do đó gặp hạn chế khi xử lý dữ liệu phức tạp.

Ngược lại, các mô hình học máy như Random Forest, XGBoost và mạng nơ-ron nhân tạo cho phép khai thác hiệu quả các cấu trúc phi tuyến và tương tác phức tạp trong dữ liệu. Nhờ khả năng học tự động từ dữ liệu, các mô hình này có thể tích hợp nhiều nguồn thông tin khác nhau, bao gồm cả dữ liệu thay thế, từ đó nâng cao độ chính xác dự báo rủi ro tín dụng. Tuy nhiên, một thách thức đáng kể của các phương pháp này là tính “hộp đen”, trong đó quá trình ra quyết định không được thể hiện một cách minh bạch và khó có thể diễn giải đối với người dùng. Bên cạnh đó, việc triển khai các mô hình học máy thường đòi hỏi tài nguyên tính toán lớn cũng như quy trình lựa chọn và tối ưu hóa tham số phức tạp.

Lessmann và cộng sự (2015) cho thấy việc lựa chọn mô hình trong chấm điểm tín dụng thường gắn với sự đánh đổi giữa khả năng giải thích và hiệu quả phân loại. Theo đó, các mô hình truyền thống phù hợp hơn trong những trường hợp cần ưu tiên tính minh bạch và khả năng giải trình, trong khi các mô hình học máy thường được lựa chọn khi mục tiêu chính là nâng cao hiệu quả dự báo [5].

1.3.2 Các mô hình phổ biến trong dự báo vỡ nợ

Trong các nghiên cứu về chấm điểm tín dụng, hồi quy logistic (Logistic Regression – LR) thường được sử dụng như một mô hình chuẩn đối chứng do cấu trúc đơn giản và khả năng diễn giải cao. Về mặt phương pháp, LR chuyển đổi các biến đầu vào thành xác suất vỡ nợ thông qua hàm sigmoid, cho phép mô hình hóa trực tiếp mối quan hệ giữa các đặc trưng và khả năng không thực hiện nghĩa vụ tài chính. Nhờ đó, kết quả dự báo có thể được giải thích rõ ràng thông qua hệ số của từng biến, điều này đặc biệt quan trọng trong môi trường tài chính yêu cầu tính minh bạch và khả năng giải trình.

Tuy nhiên, nhằm cải thiện hiệu quả dự báo trong bối cảnh dữ liệu ngày càng phức tạp, các phương pháp học máy đã được áp dụng rộng rãi. Một trong những phương pháp tiêu biểu là Random Forest, một thuật toán tập hợp dựa trên lấy mẫu có hoàn lại (bagging), trong đó nhiều cây quyết định được huấn luyện trên các tập dữ liệu con khác nhau và kết quả được tổng hợp thông qua cơ chế biểu quyết đa số (majority voting). Cách tiếp cận này giúp giảm thiểu hiện tượng quá khớp và nâng cao khả năng tổng quát hóa của mô hình.

Ngoài các nhóm mô hình trên, Support Vector Machine (SVM) cũng được ghi nhận trong tài liệu nghiên cứu như một phương pháp phân loại phi tuyến thông qua cơ chế kernel. Tuy nhiên, SVM không được đưa vào thực nghiệm của nghiên cứu này vì ba lý do chính: chi phí tính toán cao trên tập dữ liệu 30.000 quan sát; khả năng tích hợp kém hơn với các phương pháp XAI mô hình dựa trên cây quyết định (tree-based) như TreeSHAP; và kết quả benchmark của Lessmann và cộng sự (2015) cho thấy các phương pháp ensemble thường vượt trội SVM trong bài toán chấm điểm tín dụng [5]. Phạm vi thực nghiệm vì vậy tập trung vào Logistic Regression, Random Forest và XGBoost là ba nhóm phương pháp phổ biến nhất và tương thích tốt nhất với mục tiêu kết hợp dự báo và giải thích mô hình của đề tài.

Ngoài ra, các phương pháp tăng cường như XGBoost đã chứng minh hiệu quả vượt trội trong nhiều bài toán dự báo rủi ro tín dụng. Thuật toán này xây dựng mô hình theo cách tuần tự, trong đó mỗi bước học nhằm giảm thiểu sai số của các mô hình trước đó, đồng thời tích hợp các kỹ thuật điều chuẩn để hạn chế quá khớp. Nhờ khả năng xử lý dữ liệu mất cân bằng và giá trị thiếu, XGBoost thường đạt hiệu suất dự báo cao trên các bộ dữ liệu thực tế. Kết quả từ các nghiên cứu so sánh quy mô lớn cũng cho thấy các phương pháp học máy, đặc biệt là các mô hình kết hợp và tăng cường, thường đạt hiệu suất dự báo cao hơn so với các phương pháp truyền thống trong nhiều bối cảnh thực nghiệm [5].

Mặc dù các mô hình Machine Learning mang lại hiệu suất dự báo cao, đặc biệt trong việc xử lý dữ liệu phi tuyến và phức tạp, các mô hình này thường thiếu

khả năng giải thích do cấu trúc nội tại phức tạp. Điều này tạo ra thách thức trong việc áp dụng vào lĩnh vực tài chính, nơi các quyết định tín dụng đòi hỏi tính minh bạch và khả năng giải trình. Do đó, nhu cầu về các phương pháp có thể giải thích mô hình đã thúc đẩy sự phát triển của Explainable Artificial Intelligence (XAI).

1.4 Explainable AI trong tài chính

1.4.1 Khái niệm XAI

Arrieta và cộng sự (2020) định nghĩa Explainable Artificial Intelligence (XAI) là tập hợp các kỹ thuật cho phép con người hiểu và tin tưởng vào kết quả từ các mô hình học máy, đặc biệt trong các ứng dụng có rủi ro cao hoặc yêu cầu giải trình [8]. Theo đó, XAI không nên được hiểu như một thuật toán đơn lẻ, mà là một định hướng thiết kế nhằm nâng cao tính minh bạch và khả năng giải thích của mô hình.

Adadi và Berrada (2018) cung cấp khảo sát toàn diện về các kỹ thuật XAI, trong đó nhấn mạnh rằng phần lớn ứng dụng hiện tại còn thiếu cầu nối giữa khả năng giải thích kỹ thuật và yêu cầu giải trình trong bối cảnh ra quyết định thực tiễn [19]. Guidotti và cộng sự (2018) cho rằng tính “hộp đen” của mô hình không chỉ nằm ở chỗ thuật toán khó diễn giải, mà còn ở việc dữ liệu huấn luyện thiếu minh bạch và kết quả dự báo không đi kèm lý do giải thích [6]. Trong bài toán tín dụng, điểm cuối cùng đặc biệt đáng chú ý, vì các quyết định cấp tín dụng thường cần có căn cứ giải trình rõ ràng. Chính vì vậy, XAI được quan tâm như một hướng tiếp cận nhằm hỗ trợ giải thích cho từng dự báo cụ thể, thay vì chỉ mô tả cơ chế hoạt động chung của mô hình [8] [6] [7].

Theo Arrieta và cộng sự (2020), một hệ thống AI đáng tin cậy không chỉ cần đạt hiệu quả dự báo, mà còn phải bảo đảm tính minh bạch, khả năng giải thích và trách nhiệm giải trình [8]. Trong bối cảnh này, XAI có ý nghĩa quan trọng vì giúp làm rõ cơ sở hình thành dự báo của mô hình, từ đó hỗ trợ việc kiểm tra và sử dụng kết quả trong thực tiễn. Bên cạnh đó, trong các trường hợp có sử dụng ra quyết định tự động, khung pháp lý của Liên minh châu Âu như GDPR cũng đặt ra yêu

cầu cung cấp thông tin có ý nghĩa về logic liên quan đến quyết định trong những trường hợp nhất định.

Về phương pháp, các kỹ thuật XAI có thể được phân loại theo phạm vi giải thích. Giải thích cục bộ tập trung vào việc diễn giải một dự đoán cụ thể, trong khi giải thích toàn cục nhằm mô tả hành vi tổng thể của mô hình. Các phương pháp không phụ thuộc mô hình như SHAP và LIME cho phép áp dụng linh hoạt trên nhiều loại thuật toán khác nhau [6].

1.4.2 Tầm quan trọng của Explainable AI trong chấm điểm tín dụng

Lessmann và cộng sự (2015) cho thấy các mô hình học máy, đặc biệt là các phương pháp ensemble và boosting, thường đạt hiệu quả phân loại cao hơn so với hồi quy logistic trên nhiều bộ dữ liệu chấm điểm tín dụng [5]. Tuy nhiên, trong thực tiễn tài chính, độ chính xác dự báo cao chưa phải là điều kiện duy nhất để mô hình được chấp nhận, bởi các quyết định tín dụng còn gắn với yêu cầu minh bạch và khả năng giải trình.

Trong lĩnh vực tín dụng, yêu cầu giải trình là một lý do quan trọng khiến XAI được quan tâm nhiều hơn. Bussmann và cộng sự (2021) cho thấy rằng ở nhiều thị trường, các quyết định tín dụng ngày càng phải đáp ứng yêu cầu minh bạch và bảo vệ người tiêu dùng [7]. Vì vậy, tổ chức tín dụng không thể chỉ đưa ra kết quả chấp thuận hay từ chối, mà còn cần có căn cứ để giải thích quyết định đối với từng hồ sơ. Điều này làm cho các mô hình “hộp đen” gặp khó khăn hơn trong triển khai thực tế nếu không đi kèm với công cụ giải thích phù hợp [7].

Từ góc độ vận hành, điều này cũng cho thấy độ chính xác dự báo cao chưa phải là điều kiện duy nhất để một mô hình được chấp nhận trong thực tiễn. Một mô hình như Random Forest có thể đạt hiệu quả phân loại cao hơn Logistic Regression, nhưng vẫn khó tích hợp vào quy trình phê duyệt nếu không giải thích được lý do của từng dự báo. Ngược lại, một mô hình có hiệu suất thấp hơn nhưng minh bạch hơn lại có thể thuận lợi hơn trong kiểm tra, giám sát và sử dụng trong môi trường quản trị rủi ro.

Arrieta và cộng sự (2020) cũng nhấn mạnh rằng khả năng giải thích không chỉ là một yêu cầu kỹ thuật, mà còn là điều kiện để người sử dụng có thể đánh giá, kiểm tra và phản biện kết quả mô hình một cách có căn cứ [8]. Trong thực tế, nếu mô hình không thể giải thích, việc tích hợp vào quy trình ra quyết định sẽ trở nên khó khăn hơn, đặc biệt khi con người vẫn là chủ thể chịu trách nhiệm phê duyệt cuối cùng.

Bên cạnh yêu cầu giải trình, XAI còn có giá trị trong việc hỗ trợ đánh giá chất lượng mô hình trước khi triển khai. Molnar (2022) cho rằng việc phân tích Feature Importance và SHAP values có thể giúp phát hiện những biến đang được mô hình gán mức ảnh hưởng cao do tương quan trong dữ liệu lịch sử, thay vì phản ánh trực tiếp bản chất của rủi ro vỡ nợ [20]. Vấn đề này đặc biệt đáng lưu ý khi dữ liệu thay đổi theo thời gian, vì nó có thể làm suy giảm hiệu quả của mô hình sau triển khai. Trong số các phương pháp giải thích hiện nay, Lundberg và Lee (2017) đề xuất SHAP dựa trên lý thuyết giá trị SHAPley, qua đó cung cấp một cách phân bổ đóng góp biến nhất quán hơn cho từng dự báo [9]. Đây là lý do quan trọng khiến SHAP phù hợp hơn trong các trường hợp cần giải thích kết quả theo hướng có thể kiểm tra và đối chiếu lại.

1.4.3 Các phương pháp giải thích mô hình (SHAP, Feature Importance)

Trong lĩnh vực Explainable Artificial Intelligence (XAI), các phương pháp giải thích mô hình thường được chia thành hai nhóm chính là giải thích toàn cục và giải thích cục bộ. Giải thích toàn cục nhằm làm rõ cách mô hình hoạt động trên toàn bộ tập dữ liệu, trong khi giải thích cục bộ tập trung vào việc lý giải một dự đoán cụ thể đối với từng quan sát [6]. Việc phân biệt hai nhóm này có ý nghĩa quan trọng vì chúng phục vụ những mục tiêu khác nhau trong quá trình phân tích và ứng dụng mô hình.

Trong số các kỹ thuật giải thích phổ biến, Feature Importance thường được sử dụng để đánh giá mức độ ảnh hưởng tương đối của các biến đầu vào đối với kết quả dự báo. Có hai cách tiếp cận thường gặp. Thứ nhất là Impurity-based Feature Importance hay Mean Decrease in Impurity (MDI), được xác định dựa

trên mức giảm impurity trong quá trình huấn luyện các mô hình dựa trên cây quyết định hoặc mô hình tập hợp dựa trên cây [21]. Thứ hai là Permutation Importance, trong đó tầm quan trọng của biến được đánh giá thông qua mức suy giảm hiệu suất mô hình khi giá trị của biến đó bị xáo trộn ngẫu nhiên [20]. Hai phương pháp này có thể cho kết quả khác nhau, nhất là khi các biến đầu vào có tương quan với nhau.

Bên cạnh đó, SHAP (SHAPley Additive exPlanations) là một phương pháp giải thích nổi bật dựa trên giá trị SHAPley trong lý thuyết trò chơi. Phương pháp này cho phép lượng hóa mức đóng góp của từng biến đầu vào đối với kết quả dự đoán một cách nhất quán, đồng thời có thể sử dụng cho cả giải thích toàn cục và giải thích cục bộ [9]. Nhờ đặc điểm này, SHAP đặc biệt phù hợp với các mô hình phức tạp như Random Forest hoặc XGBoost, vốn có hiệu quả dự báo cao nhưng khó diễn giải trực tiếp.

Ngoài ra, LIME (Local Interpretable Model-agnostic Explanations) cũng là một phương pháp phổ biến trong giải thích cục bộ. LIME hoạt động bằng cách xấp xỉ mô hình phức tạp bằng một mô hình đơn giản hơn trong vùng lân cận của từng quan sát, từ đó tạo ra lời giải thích dễ hiểu cho từng dự đoán cụ thể [10].

Trong nghiên cứu này, SHAP được sử dụng làm phương pháp giải thích chính nhằm phân tích kết quả mô hình ở cả hai cấp độ. Ở cấp độ toàn cục, SHAP giúp xác định những biến có đóng góp lớn vào dự báo rủi ro vỡ nợ. Ở cấp độ cục bộ, phương pháp này cho phép xem xét cách từng biến ảnh hưởng đến dự báo của một hồ sơ khách hàng cụ thể. Do Random Forest và XGBoost đều là các mô hình dựa trên cây quyết định, nghiên cứu sử dụng TreeSHAP để tính toán giá trị SHAP một cách phù hợp và hiệu quả hơn [9]. TreeSHAP khai thác cấu trúc cây quyết định để tính SHAP values một cách chính xác và hiệu quả hơn KernelSHAP tổng quát, đồng thời không phụ thuộc vào số lượng mẫu nền (background samples). Đây là lý do TreeSHAP phù hợp hơn với mục tiêu giải thích mô hình trong bài toán tín dụng [9].

1.5 Tổng quan các nghiên cứu liên quan

1.5.1 Nghiên cứu về Machine Learning trong chấm điểm tín dụng

Các nghiên cứu về chấm điểm tín dụng truyền thống chủ yếu dựa trên các phương pháp thống kê như hồi quy logistic, vốn được đánh giá cao nhờ tính đơn giản và khả năng diễn giải rõ ràng. Hand và Henley (1997) cho rằng các phương pháp này đóng vai trò nền tảng trong chấm điểm tín dụng, đặc biệt trong môi trường quản lý yêu cầu tính minh bạch cao [3]. Tuy nhiên, các mô hình này thường giả định mối quan hệ tuyến tính và do đó gặp hạn chế trong việc phản ánh các hành vi tài chính phức tạp.

Sự phát triển của Machine Learning đã mở ra hướng tiếp cận mới cho bài toán này. Nghiên cứu của Yeh và Lien (2009), sử dụng bộ dữ liệu thẻ tín dụng với 30.000 quan sát, cho thấy các phương pháp học máy có thể cải thiện đáng kể độ chính xác dự báo xác suất vỡ nợ so với các mô hình truyền thống [11]. Trên cơ sở đó, nhiều nghiên cứu tiếp theo đã sử dụng cùng bộ dữ liệu này để đánh giá hiệu quả của các thuật toán học máy.

Một trong những nghiên cứu có ảnh hưởng lớn là công trình của Lessmann và cộng sự (2015), trong đó hơn 40 thuật toán phân loại đã được so sánh trên nhiều bộ dữ liệu chấm điểm tín dụng khác nhau. Kết quả cho thấy các phương pháp học máy, đặc biệt là các mô hình ensemble và boosting, thường đạt hiệu suất vượt trội so với hồi quy logistic [5]. Ngoài ra, Chen và Guestrin (2016) đã đề xuất XGBoost – một thuật toán boosting hiệu quả cao, được chứng minh đạt kết quả vượt trội trong nhiều bài toán phân loại, bao gồm cả dự báo rủi ro tín dụng [22].

Bên cạnh việc lựa chọn thuật toán, nhiều nghiên cứu cũng tập trung vào xử lý dữ liệu, đặc biệt là vấn đề mất cân bằng lớp. Chawla và cộng sự (2002) đã đề xuất phương pháp SMOTE nhằm cải thiện khả năng nhận diện lớp thiểu số, qua đó nâng cao hiệu suất mô hình trong các bài toán tín dụng [23].

Tuy nhiên, có thể nhận thấy rằng phần lớn các nghiên cứu về Machine Learning trong chấm điểm tín dụng đều tập trung vào việc tối ưu hóa độ chính xác dự báo, thông qua việc so sánh thuật toán hoặc cải tiến mô hình. Ba hạn chế

chính có thể chỉ ra: thứ nhất, ngưỡng phân loại thường được giữ mặc định ở 0,5 thay vì tối ưu theo chi phí rủi ro thực tế; thứ hai, bộ dữ liệu mất cân bằng thường chưa được xử lý một cách nhất quán bên trong pipeline cross-validation, dẫn đến rủi ro data leakage; thứ ba, các khía cạnh như khả năng giải thích và ý nghĩa kinh tế của các biến đầu vào thường chưa được phân tích đầy đủ, dẫn đến khoảng cách giữa kết quả học thuật và ứng dụng vận hành tín dụng.

1.5.2 Nghiên cứu về XAI trong chấm điểm tín dụng

Trước hạn chế về tính minh bạch của các mô hình học máy, Explainable Artificial Intelligence (XAI) đã được phát triển nhằm làm rõ cơ chế ra quyết định của các mô hình “hộp đen”. Guidotti và cộng sự (2018) đã tổng hợp và phân loại các phương pháp giải thích mô hình, chỉ ra rằng XAI không chỉ giúp tăng tính minh bạch mà còn hỗ trợ kiểm toán và kiểm soát các hệ thống AI [6].

Trong số các phương pháp XAI, SHAP là một trong những kỹ thuật nổi bật nhờ nền tảng lý thuyết vững chắc. Lundberg và Lee (2017) đã đề xuất phương pháp này dựa trên giá trị SHAPley, cho phép phân bổ đóng góp của từng biến đầu vào vào kết quả dự đoán một cách nhất quán [9]. Nhờ khả năng cung cấp cả giải thích cục bộ và toàn cục, SHAP được ứng dụng rộng rãi trong các bài toán chấm điểm tín dụng sử dụng mô hình dựa trên cây quyết định.

Ngoài ra, các phương pháp như Feature Importance, Permutation Importance và LIME cũng được sử dụng để giải thích mô hình. Molnar (2022) cho thấy Permutation Importance là một phương pháp trực quan nhưng có thể bị ảnh hưởng bởi tương quan giữa các biến [20]. Trong khi đó, LIME cung cấp giải thích cục bộ thông qua việc xấp xỉ mô hình phức tạp bằng mô hình đơn giản hơn trong phạm vi lân cận của từng quan sát.

Trong lĩnh vực tín dụng, Bussmann và cộng sự (2021) nhấn mạnh rằng XAI đóng vai trò quan trọng trong quản trị rủi ro, đặc biệt trong việc đáp ứng yêu cầu minh bạch và khả năng giải trình của các cơ quan quản lý [7]. Tuy nhiên, phần lớn các nghiên cứu XAI trong tín dụng còn tồn tại hai hạn chế đáng chú ý. Thứ nhất, giải thích SHAP thường được trình bày ở cấp độ toàn cục (global feature

importance) mà chưa được kết nối với quy trình ra quyết định cụ thể - ví dụ, một khách hàng bị từ chối cần được thông báo lý do dựa trên các biến SHAP cá nhân, không chỉ dựa trên importance tổng thể. Thứ hai, các nghiên cứu thường bỏ qua vấn đề calibration của xác suất dự báo; khi SHAP được áp dụng trên mô hình chưa calibrated, các giải thích về mức rủi ro có thể bị diễn giải sai. Hai hạn chế này tạo ra khoảng trống thực tiễn rõ ràng mà đề tài hướng đến giải quyết thông qua framework ML + XAI tích hợp.

1.5.3 Tổng hợp và phê bình các hướng nghiên cứu

Tổng hợp các nghiên cứu cho thấy hai xu hướng chính trong lĩnh vực chấm điểm tín dụng. Thứ nhất, các nghiên cứu về Machine Learning tập trung vào việc cải thiện hiệu suất dự báo thông qua các thuật toán phức tạp và kỹ thuật xử lý dữ liệu. Thứ hai, các nghiên cứu về XAI hướng đến việc nâng cao khả năng giải thích nhằm đảm bảo tính minh bạch và tuân thủ trong các ứng dụng tài chính.

Tuy nhiên, tồn tại một khoảng cách rõ rệt giữa hai hướng tiếp cận này. Các nghiên cứu về Machine Learning thường ưu tiên độ chính xác nhưng thiếu khả năng giải thích, trong khi các nghiên cứu XAI lại chủ yếu tập trung vào việc diễn giải mô hình sau khi đã xây dựng. Ngoài ra, mặc dù bộ dữ liệu “Default of Credit Card Clients Dataset” được sử dụng rộng rãi, nhiều nghiên cứu chưa khai thác sâu ý nghĩa của các biến hành vi trong việc hỗ trợ ra quyết định tín dụng.

Trong phạm vi các tài liệu được tổng quan, có thể thấy nhiều nghiên cứu tập trung vào so sánh hiệu quả thuật toán, trong khi việc tích hợp giải thích mô hình vào quy trình hỗ trợ quyết định tín dụng vẫn chưa được phân tích đầy đủ. Điều này cho thấy vẫn còn thiếu các nghiên cứu kết hợp chặt chẽ giữa hiệu suất dự báo và khả năng giải thích trong bối cảnh thực tiễn. Cụ thể hơn, có thể nhận diện ba điểm chưa được giải quyết trong tài liệu nghiên cứu hiện có: (i) việc tối ưu ngưỡng quyết định gắn với chi phí rủi ro tín dụng thay vì chỉ dựa vào F1-score hoặc Accuracy; (ii) việc chuyển hóa kết quả SHAP thành bảng hỗ trợ quyết định có thể sử dụng trong vận hành tín dụng; và (iii) sự kết hợp đồng thời giữa feature engineering hành vi (late_count, util_rate, pay_ratio) với giải thích SHAP để làm

rõ ý nghĩa nghiệp vụ của từng biến. Đây chính là ba nội dung mà đề tài hướng đến.

Từ đó, có thể xác định khoảng trống nghiên cứu nằm ở việc xây dựng một mô hình kết hợp giữa Machine Learning và Explainable AI trên cùng một bộ dữ liệu chuẩn, nhằm vừa đảm bảo độ chính xác dự báo, vừa cung cấp các giải thích có ý nghĩa thực tiễn đối với các yếu tố ảnh hưởng đến rủi ro tín dụng.

1.6 Khoảng trống nghiên cứu

Từ tổng quan tài liệu có thể thấy các nghiên cứu về chấm điểm tín dụng cá nhân thường phát triển theo hai hướng chính. Hướng thứ nhất tập trung vào cải thiện hiệu quả dự báo bằng các mô hình Machine Learning như Random Forest, SVM, Gradient Boosting hoặc XGBoost; các nghiên cứu benchmark lớn cho thấy nhóm mô hình này thường đạt hiệu quả tốt hơn các mô hình thống kê truyền thống trong nhiều bộ dữ liệu chấm điểm tín dụng [5], [22]. Hướng thứ hai tập trung vào khả năng giải thích của mô hình thông qua Explainable AI, đặc biệt là SHAP, nhằm làm rõ mức đóng góp của từng biến vào dự báo [9], [6], [7].

Tuy nhiên, vẫn tồn tại khoảng cách giữa hiệu quả dự báo và khả năng ứng dụng kết quả mô hình trong quyết định tín dụng. Một bộ phận đáng kể các nghiên cứu trước chủ yếu tập trung vào so sánh chỉ số như Accuracy, ROC-AUC hoặc F1-score, trong khi thực tiễn tín dụng đòi hỏi mô hình không chỉ dự báo tốt mà còn phải giải thích được lý do xếp hạng rủi ro và hỗ trợ quyết định một cách minh bạch [5], [7]. Theo Miles (2017), khoảng trống thực tiễn phản ánh sự mất kết nối giữa tri thức học thuật và ứng dụng thực tế, trong khi khoảng trống phương pháp xuất hiện khi các nghiên cứu trước chưa khai thác đầy đủ một cách tiếp cận hoặc quy trình phương pháp khác [24]. Theo cách tiếp cận này, đề tài xác định khoảng trống nghiên cứu ở sự kết hợp giữa khoảng trống thực tiễn và khoảng trống phương pháp trong bài toán chấm điểm tín dụng.

Đối với bộ dữ liệu *Default of Credit Card Clients Dataset*, nhiều nghiên cứu đã sử dụng dữ liệu này để đánh giá các thuật toán dự báo vỡ nợ [11]. Tuy nhiên, phần lớn các công trình này dừng lại ở việc so sánh chỉ số AUC hoặc Accuracy

mà chưa kết nối kết quả giải thích mô hình với quy trình ra quyết định tín dụng thực tế. Adadi và Berrada (2018) chỉ ra rằng khoảng cách giữa khả năng giải thích kỹ thuật và yêu cầu giải trình trong ứng dụng tài chính vẫn là một hạn chế phổ biến trong văn liệu XAI [19]. Bussmann và cộng sự (2021) cũng lưu ý rằng việc chuyển hóa điểm rủi ro thành khuyến nghị hành động cụ thể kết hợp với giải thích SHAP cấp cá nhân vẫn còn thiếu trong phần lớn nghiên cứu học thuật [7]. Cụ thể, giá trị thực tiễn của các biến hành vi đặc trưng của bộ dữ liệu này như lịch sử thanh toán (PAY_0–PAY_6), số kỳ trễ hạn tổng hợp, hạn mức tín dụng và tỷ lệ sử dụng hạn mức chưa được phân tích đầy đủ theo hướng hỗ trợ phân loại và phê duyệt tín dụng. Chính khoảng cách giữa kết quả mô hình và ứng dụng vận hành này tạo nên cơ sở xác định khoảng trống nghiên cứu của đề tài.

Từ đó, khoảng trống nghiên cứu của khóa luận được xác định là: cần xây dựng một quy trình kết hợp giữa Machine Learning và Explainable AI cho bài toán dự báo rủi ro vỡ nợ, trong đó mô hình không chỉ được đánh giá bằng hiệu suất dự báo mà còn được giải thích và chuyển hóa thành căn cứ hỗ trợ quyết định tín dụng minh bạch. Trên cơ sở đó, đề tài so sánh Logistic Regression, Random Forest và XGBoost; xử lý mất cân bằng bằng SMOTE trong pipeline; tối ưu ngưỡng phân loại theo F2-score; sử dụng SHAP để giải thích mô hình; đồng thời xây dựng phân nhóm rủi ro và decision table nhằm minh họa khả năng ứng dụng trong quản trị rủi ro tín dụng. Vì vậy, đóng góp của khóa luận không nằm ở việc đề xuất một thuật toán mới, mà ở việc tích hợp các bước dự báo, giải thích và hỗ trợ quyết định vào cùng một quy trình thực nghiệm có thể kiểm chứng.

1.7 Khung nghiên cứu đề xuất

Khung nghiên cứu của đề tài được xây dựng từ khoảng trống đã xác định ở phần tổng quan. Trọng tâm của khung này là kết hợp hai yêu cầu: nâng cao hiệu quả dự báo bằng các mô hình Machine Learning và tăng khả năng giải thích thông qua XAI. Mục tiêu cuối cùng là tạo ra một mô hình vừa có giá trị dự báo, vừa có thể hỗ trợ ra quyết định tín dụng trong thực tế.

Cụ thể, quy trình nghiên cứu được thiết kế theo hướng tuần tự gồm ba thành phần chính. Thứ nhất, dữ liệu được tiền xử lý nhằm đảm bảo chất lượng đầu vào, bao gồm xử lý giá trị thiếu, chuẩn hóa và lựa chọn đặc trưng. Thứ hai, các mô hình Machine Learning gồm Logistic Regression, Random Forest và XGBoost, cùng Dummy Classifier làm mốc tham chiếu, được xây dựng nhằm dự báo xác suất vỡ nợ, qua đó lựa chọn mô hình có hiệu suất tối ưu dựa trên các tiêu chí đánh giá phù hợp. Thứ ba, các phương pháp XAI, đặc biệt là SHAP, được tích hợp nhằm phân tích và diễn giải mức độ ảnh hưởng của các biến đầu vào đến kết quả dự báo.

Điểm khác biệt của khung nghiên cứu này so với các công trình trước nằm ở việc phân tích SHAP được xem là thành phần bắt buộc để trả lời câu hỏi nghiên cứu, thay vì chỉ đóng vai trò minh họa sau khi đã kết luận về mô hình. Về mặt kỹ thuật, SHAP vẫn là phương pháp giải thích hậu xử lý (post-hoc), song trong nghiên cứu này kết quả SHAP được sử dụng trực tiếp để trả lời câu hỏi về các yếu tố ảnh hưởng đến rủi ro tín dụng. Điều này cho phép kết nối trực tiếp giữa kết quả dự báo và ý nghĩa kinh tế của các biến, từ đó nâng cao khả năng ứng dụng của mô hình trong quản trị rủi ro tín dụng.

1.8 Kết luận chương

Chương 1 đã trình bày cơ sở lý luận về rủi ro tín dụng, chấm điểm tín dụng, Machine Learning và Explainable AI, đồng thời tổng hợp các nghiên cứu liên quan để xác định khoảng trống nghiên cứu của đề tài. Kết quả tổng quan cho thấy các mô hình học máy có tiềm năng cải thiện hiệu quả dự báo, nhưng phần lớn nghiên cứu hiện tại chưa kết nối đầy đủ giữa giải thích mô hình và hỗ trợ quyết định vận hành. Ba khoảng trống cụ thể được xác định: tối ưu ngưỡng theo chi phí rủi ro, chuyển hóa SHAP thành decision table, và kết hợp feature engineering hành vi với giải thích cấp cá nhân. Khung nghiên cứu của đề tài được xây dựng để giải quyết đồng thời cả ba khoảng trống này, tạo nền tảng phương pháp cho Chương 2.

CHƯƠNG 2 DỮ LIỆU VÀ PHƯƠNG PHÁP NGHIÊN CỨU

Trên cơ sở lý luận và khoảng trống nghiên cứu đã trình bày ở Chương 1, Chương 2 trình bày dữ liệu và phương pháp nghiên cứu được sử dụng trong khóa luận. Nội dung chương tập trung vào các quyết định phương pháp chính, bao gồm mô tả dữ liệu, phân chia tập huấn luyện và tập kiểm tra, tiền xử lý dữ liệu, xây dựng đặc trưng, xử lý mất cân bằng lớp, xây dựng mô hình, đánh giá mô hình, tối ưu ngưỡng phân loại và giải thích kết quả bằng SHAP.

Để giữ nội dung chính tập trung vào logic nghiên cứu, các công thức và cấu hình kỹ thuật chi tiết được trình bày tại phụ lục. Cụ thể, công thức xây dựng đặc trưng được trình bày tại Phụ lục C; công thức SMOTE và các chỉ số đánh giá được trình bày tại Phụ lục D; cấu hình mô hình và tham số tối ưu được trình bày tại Phụ lục F.

2.1 Mô tả dữ liệu

Bộ dữ liệu sử dụng trong nghiên cứu là Default of Credit Card Clients Dataset, được công bố trên UCI Machine Learning Repository và được sử dụng phổ biến trong các nghiên cứu về chấm điểm tín dụng và dự báo rủi ro vỡ nợ. Bộ dữ liệu phản ánh thông tin của khách hàng sử dụng thẻ tín dụng, bao gồm đặc điểm cá nhân, hạn mức tín dụng, lịch sử thanh toán, dư nợ sao kê, số tiền thanh toán và trạng thái vỡ nợ trong kỳ tiếp theo.

File dữ liệu gốc gồm 30.001 dòng và 25 cột. Sau khi kiểm tra cấu trúc dữ liệu, dòng đầu tiên trong phần dữ liệu được xác định là dòng chứa tên biến. Vì vậy, sau khi xử lý lại hàng tiêu đề, bộ dữ liệu nghiên cứu thực tế gồm 30.000 quan sát. Trong đó, dữ liệu bao gồm một biến định danh ID, 23 biến đầu vào và một biến mục tiêu.

Biến mục tiêu ban đầu có tên default payment next month và được đổi tên thành default trong quá trình xử lý dữ liệu. Đây là biến nhị phân, nhận giá trị 1 nếu khách hàng vỡ nợ trong kỳ tiếp theo và nhận giá trị 0 nếu khách hàng không vỡ nợ. Trong tổng số 30.000 quan sát, có 6.636 khách hàng vỡ nợ (default = 1), chiếm tỷ lệ 22,12%, và 23.364 khách hàng không vỡ nợ (default = 0), chiếm tỷ lệ

77,88%. Sự mất cân bằng lớp này là đặc điểm quan trọng của bộ dữ liệu và là lý do nghiên cứu áp dụng SMOTE cùng các chỉ số đánh giá phù hợp với dữ liệu mất cân bằng như Recall, F2-score và PR-AUC thay vì chỉ dựa vào Accuracy.

Các biến đầu vào có thể được chia thành bốn nhóm chính. Nhóm thứ nhất là các biến đặc điểm cá nhân và thông tin tín dụng cơ bản, bao gồm LIMIT_BAL, SEX, EDUCATION, MARRIAGE và AGE. Nhóm thứ hai là các biến lịch sử thanh toán trong sáu kỳ gần nhất, bao gồm PAY_0, PAY_2, PAY_3, PAY_4, PAY_5 và PAY_6. Nhóm thứ ba là các biến dư nợ sao kê, gồm BILL_AMT1 đến BILL_AMT6. Nhóm thứ tư là các biến số tiền thanh toán thực tế, gồm PAY_AMT1 đến PAY_AMT6.

Cấu trúc dữ liệu này phù hợp với mục tiêu nghiên cứu vì cho phép mô hình khai thác đồng thời thông tin về hạn mức tín dụng, lịch sử thanh toán, dư nợ và hành vi trả nợ của khách hàng. Đây là các nhóm biến có ý nghĩa trực tiếp trong bài toán dự báo rủi ro vỡ nợ và giải thích kết quả mô hình bằng Explainable AI.

2.2 Phân chia dữ liệu và thiết kế tập holdout

Bộ dữ liệu được chia thành tập huấn luyện và tập kiểm tra holdout theo tỷ lệ 80:20. Với tổng số 30.000 quan sát, tập huấn luyện gồm 24.000 quan sát, trong khi tập kiểm tra holdout gồm 6.000 quan sát. Việc phân chia được thực hiện theo phương pháp phân tầng dựa trên biến mục tiêu default, nhằm duy trì tương đối ổn định tỷ lệ khách hàng vỡ nợ và không vỡ nợ ở cả hai tập dữ liệu.

Tập huấn luyện được sử dụng cho các bước xây dựng pipeline, xử lý mất cân bằng, kiểm định chéo, tối ưu siêu tham số và lựa chọn ngưỡng phân loại. Ngược lại, tập kiểm tra holdout chỉ được sử dụng ở giai đoạn đánh giá cuối cùng nhằm kiểm tra khả năng tổng quát hóa của mô hình trên dữ liệu chưa được sử dụng trong quá trình huấn luyện.

Việc giữ riêng tập holdout có ý nghĩa quan trọng vì giúp hạn chế nguy cơ đánh giá quá lạc quan. Đặc biệt, ngưỡng phân loại theo F2-score không được lựa chọn trực tiếp trên tập holdout mà được xác định dựa trên dự báo ngoài mẫu của

tập huấn luyện thông qua kiểm định chéo. Sau khi ngưỡng được xác định, mô hình mới được đánh giá trên tập holdout.

Bảng 2.1: Thiết kế phân chia dữ liệu trong nghiên cứu

Tập dữ liệu	Tỷ lệ	Số quan sát	Vai trò
Tập huấn luyện	80%	24.000	Huấn luyện mô hình, kiểm định chéo, tối ưu tham số và lựa chọn ngưỡng
Tập kiểm tra holdout	20%	6.000	Đánh giá cuối cùng trên dữ liệu độc lập

2.3 Tiền xử lý dữ liệu và xây dựng đặc trưng

Tiền xử lý dữ liệu được thực hiện nhằm đảm bảo dữ liệu đầu vào có cấu trúc phù hợp trước khi đưa vào mô hình học máy. Trước hết, dữ liệu được chuẩn hóa lại tên biến, loại bỏ biến định danh ID và đổi tên biến mục tiêu từ default payment next month thành default để thuận tiện cho quá trình xử lý.

Đối với các biến phân loại, nghiên cứu thực hiện làm sạch một số mã giá trị bất thường. Cụ thể, các giá trị EDUCATION = 0, 5 và 6 được gộp vào nhóm 4, đại diện cho nhóm “khác”. Tương tự, giá trị MARRIAGE = 0 được gộp vào nhóm 3, cũng đại diện cho nhóm “khác”. Cách xử lý này nhằm giảm nhiễu và ổn định ý nghĩa của các biến phân loại trước khi mã hóa.

Ba biến phân loại gồm SEX, EDUCATION và MARRIAGE được mã hóa bằng One-Hot Encoding trong ColumnTransformer. Các biến số được xử lý bằng SimpleImputer và StandardScaler trong pipeline. Việc đặt các bước xử lý này trong pipeline giúp bảo đảm rằng bộ mã hóa và bộ chuẩn hóa chỉ được fit trên tập huấn luyện trong từng fold, qua đó hạn chế rò rỉ dữ liệu.

Bên cạnh các biến gốc, nghiên cứu xây dựng thêm một số đặc trưng hành vi nhằm tóm tắt thông tin về mức độ sử dụng tín dụng, khả năng thanh toán và lịch sử trễ hạn của khách hàng. Cụ thể, nghiên cứu xây dựng năm biến mới gồm avg_bill_amt, util_rate, avg_pay_amt, pay_ratio và late_count.

Bảng 2.2: Các đặc trưng hành vi được xây dựng trong nghiên cứu

Biến mới	Ý nghĩa nghiệp vụ
avg_bill_amt	Phản ánh quy mô dư nợ sao kê trung bình trong sáu kỳ gần nhất
util_rate	Phản ánh mức độ sử dụng hạn mức tín dụng của khách hàng
avg_pay_amt	Phản ánh quy mô thanh toán trung bình trong sáu kỳ gần nhất

pay_ratio	Phản ánh mức thanh toán tương đối so với dư nợ
late_count	Phản ánh tần suất trễ hạn trong sáu kỳ gần nhất

Các đặc trưng hành vi này giúp mô hình khai thác thông tin tổng hợp thay vì chỉ dựa vào từng biến riêng lẻ. Chẳng hạn, hai khách hàng có cùng dư nợ sao kê nhưng có tỷ lệ thanh toán và số kỳ trễ hạn khác nhau có thể mang mức độ rủi ro khác nhau. Công thức chi tiết của các đặc trưng này được trình bày tại Phụ lục C.

2.4 Xử lý mất cân bằng, pipeline và kiểm định chéo

Do bài toán dự báo vỡ nợ có đặc điểm mất cân bằng lớp, trong đó số lượng khách hàng không vỡ nợ thường lớn hơn số lượng khách hàng vỡ nợ, nghiên cứu sử dụng SMOTE nhằm cải thiện khả năng nhận diện lớp thiểu số. Nếu không xử lý phù hợp, mô hình có thể thiên về lớp đa số và bỏ sót nhiều khách hàng có nguy cơ vỡ nợ.

Trong nghiên cứu này, SMOTE được tích hợp trong ImbPipeline cùng với các bước tiền xử lý và mô hình hóa. Cách tổ chức này giúp đảm bảo SMOTE chỉ được áp dụng trên phần huấn luyện trong từng fold của kiểm định chéo, không áp dụng trên tập kiểm tra holdout. Nhờ đó, các quan sát tổng hợp chỉ được sinh ra từ dữ liệu huấn luyện, góp phần hạn chế rò rỉ dữ liệu và giúp kết quả đánh giá trên tập holdout đáng tin cậy hơn.

Toàn bộ quy trình mô hình hóa được thực hiện theo thứ tự: tiền xử lý dữ liệu, chuẩn hóa biến số, mã hóa biến phân loại, xử lý mất cân bằng bằng SMOTE và huấn luyện mô hình. Nghiên cứu sử dụng StratifiedKFold 5 folds trong quá trình kiểm định chéo nhằm duy trì tương đối ổn định tỷ lệ giữa nhóm vỡ nợ và không vỡ nợ trong từng fold.

Một hạn chế cần lưu ý là các biến phân loại trong nghiên cứu được mã hóa bằng One-Hot Encoding trước khi áp dụng SMOTE. Do đó, các điểm dữ liệu tổng hợp được tạo ra có thể không phản ánh hoàn toàn cấu trúc rời rạc ban đầu của biến phân loại. Vì vậy, SMOTE trong nghiên cứu này được xem là một giải pháp thực nghiệm nhằm cải thiện khả năng phát hiện khách hàng vỡ nợ. Các hướng nghiên

cứu tiếp theo có thể so sánh thêm với SMOTE-NC, class weighting hoặc các phương pháp xử lý mất cân bằng khác.

Công thức và mô tả kỹ thuật tóm tắt của SMOTE được trình bày tại Phụ lục D.

2.5 Xây dựng và tối ưu mô hình

Nghiên cứu so sánh bốn mô hình gồm Dummy Classifier, Logistic Regression, Random Forest và XGBoost. Việc lựa chọn các mô hình này nhằm bảo đảm tính đối chứng giữa mô hình tham chiếu, mô hình truyền thống và các mô hình học máy hiện đại.

Dummy Classifier được sử dụng như mô hình tham chiếu tối thiểu. Mô hình này không học cấu trúc thực sự của dữ liệu mà đưa ra dự báo dựa trên quy tắc đơn giản. Việc sử dụng Dummy Classifier giúp kiểm tra liệu các mô hình còn lại có thực sự khai thác được thông tin từ dữ liệu hay không.

Logistic Regression được lựa chọn như mô hình thống kê truyền thống và đóng vai trò baseline chính trong nghiên cứu. Đây là mô hình có cấu trúc đơn giản, dễ diễn giải và được sử dụng rộng rãi trong chấm điểm tín dụng. Tuy nhiên, Logistic Regression có hạn chế trong việc mô hình hóa các quan hệ phi tuyến và tương tác phức tạp giữa các biến.

Random Forest là mô hình học máy thuộc nhóm ensemble dựa trên nhiều cây quyết định. Mô hình này có khả năng khai thác quan hệ phi tuyến và tương tác giữa các biến hành vi tín dụng, đồng thời thường có khả năng tổng quát hóa tốt hơn một cây quyết định đơn lẻ.

XGBoost là mô hình boosting dựa trên cây quyết định, trong đó các cây được xây dựng tuần tự nhằm cải thiện sai số của các bước trước. Mô hình này thường đạt hiệu quả cao trong các bài toán phân loại có cấu trúc dữ liệu phức tạp.

Quá trình tối ưu siêu tham số được thực hiện bằng RandomizedSearchCV trên tập huấn luyện. Tiêu chí chính trong quá trình tuning là ROC-AUC, vì chỉ số này phản ánh khả năng phân biệt tổng thể giữa nhóm khách hàng vỡ nợ và không vỡ nợ trên nhiều ngưỡng phân loại khác nhau. Sau khi mô hình được tối ưu, nghiên cứu tiếp tục đánh giá bằng nhiều chỉ số khác như PR-AUC, Recall, F2-score và

KS Statistic để phản ánh đầy đủ hơn hiệu quả mô hình trong bối cảnh dữ liệu mất cân bằng.

Cấu hình mô hình và tham số tối ưu được trình bày tại Phụ lục F.

2.6 Đánh giá mô hình và tối ưu ngưỡng F2

Mô hình được đánh giá bằng nhiều chỉ số nhằm phản ánh các khía cạnh khác nhau của hiệu quả dự báo, bao gồm Accuracy, Precision, Recall, F1-score, F2-score, ROC-AUC, PR-AUC và KS Statistic. Việc sử dụng nhiều chỉ số là cần thiết vì không một chỉ số đơn lẻ nào có thể phản ánh đầy đủ chất lượng mô hình trong bài toán dự báo rủi ro tín dụng.

Accuracy phản ánh tỷ lệ dự báo đúng tổng thể, nhưng có thể gây hiểu nhầm trong trường hợp dữ liệu mất cân bằng. Một mô hình có thể đạt Accuracy cao nếu dự báo phần lớn khách hàng thuộc nhóm không vỡ nợ, nhưng vẫn bỏ sót nhiều khách hàng vỡ nợ. Vì vậy, nghiên cứu nhấn mạnh thêm các chỉ số liên quan đến khả năng nhận diện lớp vỡ nợ như Recall, F2-score và PR-AUC.

Recall phản ánh tỷ lệ khách hàng vỡ nợ thực tế được mô hình phát hiện đúng. Trong bối cảnh tín dụng, bỏ sót khách hàng có nguy cơ vỡ nợ (False Negative) thường gây rủi ro cao hơn so với việc cảnh báo nhầm một khách hàng tốt (False Positive). Tuy nhiên, việc tối đa hóa Recall đơn thuần cũng không phải mục tiêu duy nhất, vì tỷ lệ False Positive quá cao sẽ làm tăng chi phí thẩm định và giảm hiệu quả vận hành. Vì vậy, nghiên cứu sử dụng F2-score thay cho F1-score - F2 đặt trọng số cao hơn cho Recall so với Precision nhưng không loại bỏ hoàn toàn ràng buộc Precision, giúp cân bằng giữa phát hiện rủi ro và kiểm soát cảnh báo sai. Đây cũng là lý do lựa chọn mô hình phân tích chính được đặt trong bối cảnh cân bằng đa tiêu chí thay vì tối ưu một chỉ số đơn lẻ.

Bên cạnh đó, ROC-AUC được sử dụng để đánh giá khả năng phân biệt tổng thể giữa nhóm khách hàng vỡ nợ và không vỡ nợ trên nhiều ngưỡng phân loại khác nhau. PR-AUC được sử dụng bổ sung vì chỉ số này phù hợp hơn trong bối cảnh dữ liệu mất cân bằng, khi trọng tâm phân tích là lớp vỡ nợ. KS Statistic được

sử dụng để đánh giá mức độ tách biệt giữa phân phối điểm rủi ro của nhóm vỡ nợ và nhóm không vỡ nợ.

Thay vì sử dụng ngưỡng phân loại mặc định 0,5, nghiên cứu lựa chọn ngưỡng tối ưu theo F2-score trên dữ báo ngoài mẫu của tập huấn luyện thông qua kiểm định chéo. Cách tiếp cận này giúp ngưỡng phân loại phù hợp hơn với mục tiêu quản trị rủi ro, đồng thời tránh việc điều chỉnh ngưỡng trực tiếp trên tập kiểm tra holdout.

Công thức chi tiết của các chỉ số đánh giá được trình bày tại Phụ lục D.

2.7 Thiết lập ngưỡng phân nhóm rủi ro

Bên cạnh ngưỡng phân loại nhị phân, nghiên cứu thiết lập thêm các ngưỡng phân nhóm rủi ro nhằm phục vụ mục tiêu hỗ trợ quyết định tín dụng. Việc phân nhóm này có ý nghĩa quan trọng đối với Câu hỏi nghiên cứu 3, vì kết quả mô hình cần được chuyển hóa thành các nhóm rủi ro có thể diễn giải và sử dụng trong quy trình xem xét tín dụng.

Trong nghiên cứu này, xác suất vỡ nợ dự báo được chia thành ba nhóm: Low Risk, Medium Risk và High Risk. Ngưỡng rủi ro thấp được xác định tại mức 0,167, tương ứng với khoảng percentile thứ 10 của phân phối xác suất vỡ nợ dự báo trên tập holdout. Cách tiếp cận này nhằm tách nhóm khách hàng có điểm rủi ro nằm ở phần đuôi dưới của phân phối, tức nhóm mà mô hình đánh giá là có rủi ro thấp rõ rệt so với phần còn lại của danh mục. Ngưỡng này không được tối ưu hóa theo một chỉ số phân loại cụ thể mà được xác định dựa trên phân phối thực nghiệm của điểm rủi ro, do đó cần được hiệu chỉnh lại khi áp dụng trên dữ liệu nội bộ có phân phối khác. Các khách hàng có xác suất vỡ nợ dự báo thấp hơn ngưỡng này được xếp vào nhóm Low Risk.

Ngưỡng rủi ro cao được xác định tại mức 0,320, tương ứng với ngưỡng tối ưu theo F2-score trên dữ báo ngoài mẫu của tập huấn luyện. Các khách hàng có xác suất vỡ nợ dự báo từ 0,320 trở lên được xếp vào nhóm High Risk. Các khách hàng có xác suất vỡ nợ dự báo nằm trong khoảng từ 0,167 đến dưới 0,320 được xếp vào nhóm Medium Risk.

Bảng 2.3: Quy tắc phân nhóm rủi ro trong nghiên cứu

Nhóm rủi ro	Khoảng xác suất vỡ nợ dự báo	Ý nghĩa phương pháp
Low Risk	$PD < 0,167$	Nhóm có mức rủi ro tương đối thấp
Medium Risk	$0,167 \leq PD < 0,320$	Nhóm rủi ro trung gian, cần xem xét thêm
High Risk	$PD \geq 0,320$	Nhóm rủi ro cao, cần thẩm định kỹ hơn

Cần lưu ý rằng các giá trị xác suất vỡ nợ dự báo trong nghiên cứu được sử dụng chủ yếu như điểm rủi ro tương đối để xếp hạng và phân nhóm khách hàng. Do mô hình chưa được hiệu chỉnh xác suất đầy đủ bằng các phương pháp như Platt Scaling hoặc Isotonic Regression, các giá trị này không nên được diễn giải như xác suất vỡ nợ tuyệt đối trong triển khai thực tế.

2.8 Explainable AI bằng SHAP

Sau khi đánh giá và lựa chọn mô hình phân tích chính, nghiên cứu sử dụng SHAP để giải thích kết quả dự báo ở cả cấp độ toàn cục và cục bộ. SHAP được lựa chọn vì phương pháp này cho phép lượng hóa mức đóng góp của từng biến đầu vào vào kết quả dự báo của mô hình.

Ở cấp độ toàn cục, nghiên cứu sử dụng mean absolute SHAP value để xác định các biến có đóng góp trung bình lớn nhất vào dự báo rủi ro vỡ nợ. Cách tiếp cận này giúp trả lời câu hỏi nghiên cứu về những yếu tố ảnh hưởng mạnh nhất đến dự báo của mô hình. Bên cạnh đó, SHAP summary plot được sử dụng để phân tích không chỉ mức độ quan trọng của biến, mà còn cả hướng đóng góp của biến đối với xác suất vỡ nợ dự báo.

Ở cấp độ cục bộ, nghiên cứu sử dụng waterfall plot để minh họa cách từng biến làm tăng hoặc làm giảm dự báo rủi ro đối với một hồ sơ khách hàng cụ thể. Phân tích cục bộ này có ý nghĩa trong bối cảnh tín dụng vì tổ chức tài chính không chỉ cần biết mô hình hoạt động tốt ở mức tổng thể, mà còn cần có khả năng giải thích vì sao một khách hàng cụ thể được xếp vào nhóm rủi ro thấp, trung bình hoặc cao.

Để phục vụ phân tích SHAP, nghiên cứu sử dụng mẫu giải thích có phân tầng gồm 300 quan sát, trong đó 150 quan sát thuộc nhóm không vỡ nợ và 150 quan sát thuộc nhóm vỡ nợ. Cách lấy mẫu cân bằng này giúp đảm bảo rằng phân tích SHAP có đủ đại diện từ cả hai nhóm khách hàng, đặc biệt là nhóm vỡ nợ vốn chiếm tỷ lệ thấp hơn trong dữ liệu gốc. Tuy nhiên, mẫu SHAP này chỉ được sử dụng cho mục đích giải thích mô hình, không phải để huấn luyện hoặc đánh giá hiệu suất mô hình.

Do tỷ lệ 50/50 trong mẫu SHAP không phản ánh đúng phân phối tự nhiên của tập dữ liệu, kết quả SHAP cần được hiểu là phân tích nhằm làm rõ cơ chế dự báo của mô hình trên hai nhóm khách hàng, không phải là ước lượng trực tiếp về tần suất rủi ro trong toàn bộ danh mục.

Cần nhấn mạnh rằng SHAP không chứng minh quan hệ nhân quả giữa các biến và tình trạng vỡ nợ. Giá trị SHAP chỉ phản ánh cách mô hình sử dụng các biến đầu vào để hình thành dự báo trong phạm vi dữ liệu và mô hình được huấn luyện.

2.9 Kết luận chương

Chương 2 đã trình bày dữ liệu và phương pháp nghiên cứu được sử dụng trong khóa luận. Bộ dữ liệu nghiên cứu gồm 30.000 quan sát, được chia thành tập huấn luyện và tập kiểm tra holdout theo tỷ lệ 80:20 có phân tầng. Tập huấn luyện được sử dụng cho quá trình xây dựng pipeline, kiểm định chéo, tối ưu siêu tham số và lựa chọn ngưỡng phân loại, trong khi tập holdout được giữ lại để đánh giá cuối cùng.

Về xử lý dữ liệu, nghiên cứu thực hiện làm sạch các mã bất thường của EDUCATION và MARRIAGE, loại bỏ biến ID, mã hóa các biến phân loại bằng One-Hot Encoding, chuẩn hóa biến số và xây dựng thêm các đặc trưng hành vi phản ánh dư nợ, mức sử dụng hạn mức, quy mô thanh toán và tần suất trễ hạn. Toàn bộ quá trình tiền xử lý, xử lý mất cân bằng bằng SMOTE và huấn luyện mô hình được tích hợp trong ImbPipeline nhằm hạn chế rò rỉ dữ liệu.

Cuối cùng, các mô hình được đánh giá bằng nhiều chỉ số khác nhau, trong đó F2-score được sử dụng để tối ưu ngưỡng phân loại do bài toán tín dụng ưu tiên giảm nguy cơ bỏ sót khách hàng có khả năng vỡ nợ. SHAP được sử dụng để giải

thích kết quả dự báo ở cả cấp độ toàn cục và cục bộ, tạo nền tảng cho việc phân tích kết quả và trả lời các câu hỏi nghiên cứu trong Chương 3.

CHƯƠNG 3 KẾT QUẢ VÀ THẢO LUẬN

Chương 3 trình bày kết quả thực nghiệm của các mô hình dự báo rủi ro vỡ nợ, phân tích các yếu tố đóng góp vào dự báo bằng SHAP và minh họa cách chuyển hóa kết quả mô hình thành thông tin hỗ trợ quyết định tín dụng. Nội dung chương được tổ chức theo ba câu hỏi nghiên cứu: so sánh hiệu quả dự báo giữa các mô hình, xác định các yếu tố ảnh hưởng quan trọng theo SHAP và xây dựng khung hỗ trợ quyết định tín dụng dựa trên phân nhóm rủi ro.

Để giữ nội dung chính tập trung vào kết quả trọng tâm, một số kết quả bổ sung được trình bày tại phụ lục. Cụ thể, khoảng tin cậy bootstrap và so sánh chênh lệch ROC-AUC được trình bày tại Phụ lục A; kiểm tra calibration diagnostic được trình bày tại Phụ lục B; ma trận nhầm lẫn chi tiết và các tỷ lệ liên quan được trình bày tại Phụ lục E; bảng so sánh với nghiên cứu trước được trình bày tại Phụ lục G.

3.1 Kết quả và so sánh hiệu suất mô hình

Sau khi hoàn tất quá trình huấn luyện, tối ưu siêu tham số và lựa chọn ngưỡng phân loại trên tập huấn luyện, các mô hình được đánh giá trên tập kiểm tra holdout gồm 6.000 quan sát. Tập holdout không được sử dụng trong quá trình huấn luyện, tối ưu tham số hoặc lựa chọn ngưỡng, do đó kết quả đánh giá ở phần này phản ánh khả năng tổng quát hóa của mô hình trên dữ liệu chưa quan sát.

Các mô hình được so sánh bao gồm Dummy Baseline, Logistic Regression, Random Forest và XGBoost. Trong đó, Dummy Baseline được sử dụng làm mốc tham chiếu cơ sở; Logistic Regression đại diện cho nhóm mô hình truyền thống có khả năng diễn giải cao; Random Forest và XGBoost đại diện cho nhóm mô hình học máy có khả năng khai thác quan hệ phi tuyến và tương tác giữa các biến.

Trong bài toán dự báo rủi ro vỡ nợ, Accuracy không được xem là chỉ số duy nhất do dữ liệu có hiện tượng mất cân bằng lớp. Vì vậy, nghiên cứu sử dụng thêm Precision, Recall, F1-score, F2-score, ROC-AUC, PR-AUC và KS Statistic. Trong đó, Recall và F2-score được nhấn mạnh vì nghiên cứu ưu tiên giảm nguy cơ bỏ sót khách hàng có khả năng vỡ nợ.

3.1.1 Kết quả tổng hợp của các mô hình

Bảng 3.1 trình bày kết quả so sánh hiệu quả dự báo của các mô hình trên tập kiểm tra holdout. Các chỉ số Accuracy, Precision, Recall, F1-score và F2-score được tính tại ngưỡng phân loại tối ưu theo F2-score. Trong khi đó, ROC-AUC và PR-AUC đánh giá khả năng phân biệt của mô hình trên toàn bộ dải ngưỡng.

Bảng 3.1: Kết quả so sánh hiệu quả dự báo của các mô hình trên tập kiểm tra holdout

Mô hình	Dummy Baseline	Logistic Regression	Random Forest	XGBoost
Threshold	0,050	0,355	0,320	0,250
Accuracy	0,2212	0,5340	0,5665	0,5035
Precision	0,2212	0,2974	0,3179	0,2941
Recall	1,0000	0,8124	0,8380	0,8892
F1-score	0,3622	0,4354	0,4609	0,4420
F2-score	0,5868	0,6034	0,6314	0,6330
ROC-AUC	0,5000	0,7436	0,7730	0,7727
PR-AUC	0,2212	0,5039	0,5491	0,5492
KS	0,0000	0,3875	0,4193	0,4066

Kết quả tại Bảng 3.1 cho thấy Dummy Baseline có ROC-AUC = 0,5000 và KS = 0,0000, đúng với vai trò là mô hình tham chiếu không có khả năng phân biệt thực sự giữa hai nhóm khách hàng. Mặc dù Dummy Baseline đạt Recall = 1,0000, kết quả này không phản ánh khả năng dự báo tốt vì mô hình gần như dự báo toàn bộ khách hàng vào nhóm vỡ nợ. Do đó, Dummy Baseline chỉ được sử dụng như mốc so sánh tối thiểu.

So với Logistic Regression, hai mô hình học máy là Random Forest và XGBoost cho kết quả tốt hơn về khả năng phân biệt rủi ro. Logistic Regression đạt ROC-AUC = 0,7436 và PR-AUC = 0,5039. Trong khi đó, Random Forest đạt ROC-AUC = 0,7730 và PR-AUC = 0,5491; XGBoost đạt ROC-AUC = 0,7727 và

PR-AUC = 0,5492. Điều này cho thấy Random Forest và XGBoost khai thác tốt hơn các quan hệ phi tuyến và tương tác giữa các biến hành vi tín dụng so với mô hình tuyến tính truyền thống.


Tuy nhiên, chênh lệch giữa Random Forest và XGBoost rất nhỏ. Random Forest nhỉnh hơn nhẹ về ROC-AUC và KS Statistic, trong khi XGBoost nhỉnh hơn về Recall và F2-score. Cụ thể, XGBoost đạt Recall = 0,8892 và F2-score = 0,6330, nhỉnh hơn không đáng kể so với Random Forest với Recall = 0,8380 và F2-score = 0,6314. Ngược lại, Random Forest đạt ROC-AUC = 0,7730 và KS = 0,4193, cao hơn XGBoost với ROC-AUC = 0,7727 và KS = 0,4066. Vì vậy, kết quả không nên được diễn giải theo hướng Random Forest vượt trội tuyệt đối so với XGBoost; diễn giải phù hợp hơn là hai mô hình có hiệu quả gần tương đương nhưng thể hiện ưu thế ở các khía cạnh khác nhau.

Một điểm cần lưu ý là Accuracy của các mô hình không quá cao, đặc biệt đối với XGBoost với Accuracy = 0,5035. Để diễn giải đúng con số này, cần đặt trong bối cảnh: tỷ lệ lớp đa số (non-default) trong tập holdout là 77,88%, nghĩa là một mô hình luôn dự báo "không vỡ nợ" sẽ đạt Accuracy = 77,88% cao hơn nhiều so với XGBoost. Nguyên nhân là khi ngưỡng phân loại được hạ xuống 0,250 để tối ưu F2-score, XGBoost chuyển phần lớn quan sát sang nhóm dự báo vỡ nợ, làm tăng Recall lên 0,8892 nhưng kéo Accuracy xuống thấp. Đây là hệ quả tất yếu của việc tối ưu theo Recall trong dữ liệu mất cân bằng, không phản ánh chất lượng tổng thể của mô hình. Vì lý do này, Accuracy không phải chỉ số phù hợp để đánh giá mô hình trong bài toán này; các chỉ số ROC-AUC, PR-AUC và F2-score mới là căn cứ đánh giá chính.

Để kiểm tra thêm độ ổn định của kết quả, nghiên cứu sử dụng bootstrap nhằm ước lượng khoảng tin cậy 95% cho ROC-AUC, PR-AUC và chênh lệch ROC-AUC giữa các mô hình. Do các bảng bootstrap tương đối dài, kết quả chi tiết được trình bày tại Phụ lục A.


3.1.2 Đường cong ROC và Precision–Recall

Bên cạnh bảng kết quả tổng hợp, nghiên cứu sử dụng đường cong ROC và đường cong Precision–Recall để quan sát trực quan hiệu quả dự báo của các mô hình trên nhiều ngưỡng phân loại khác nhau.



Hình 3.1: Đường cong ROC của các mô hình

Hình 3.1 cho thấy Random Forest và XGBoost có đường cong ROC nằm cao hơn Logistic Regression trên phần lớn dải ngưỡng. Về mặt định lượng, Random Forest đạt ROC-AUC = 0,7730, XGBoost đạt ROC-AUC = 0,7727, trong khi Logistic Regression đạt ROC-AUC = 0,7436. Kết quả này cho thấy hai mô hình học máy cải thiện khả năng phân biệt rủi ro so với Logistic Regression. Tuy nhiên, chênh lệch ROC-AUC giữa Random Forest và XGBoost chỉ là 0,0003, vì vậy chưa đủ cơ sở để kết luận Random Forest vượt trội rõ rệt so với XGBoost.



Hình 3.2: Đường cong Precision–Recall của các mô hình

Trong bối cảnh dữ liệu mất cân bằng, đường cong Precision–Recall có ý nghĩa quan trọng vì tập trung trực tiếp vào hiệu quả nhận diện lớp võ nợ. Kết quả cho thấy PR-AUC của XGBoost đạt 0,5492, gần như tương đương Random Forest ở mức 0,5491, trong khi Logistic Regression đạt 0,5039. Điều này tiếp tục củng cố nhận định rằng Random Forest và XGBoost là hai mô hình có hiệu quả tốt nhất, nhưng khác biệt giữa hai mô hình là rất nhỏ.

3.1.3 Ma trận nhầm lẫn và tác động của ngưỡng tối ưu

Để làm rõ hơn sự đánh đổi giữa khả năng phát hiện rủi ro và số lượng cảnh báo sai, nghiên cứu phân tích ma trận nhầm lẫn tại ngưỡng tối ưu theo F2-score. Trong bối cảnh tín dụng, False Negative là loại lỗi cần đặc biệt quan tâm vì đây là trường hợp khách hàng thực tế võ nợ nhưng mô hình dự báo là không võ nợ. Ngược lại, False Positive là trường hợp khách hàng không võ nợ nhưng bị mô hình cảnh báo là có rủi ro.

Bảng 3.2: Ma trận nhầm lẫn của các mô hình tại ngưỡng tối ưu

Mô hình	True Negative	False Positive	False Negative	True Positive
Dummy Baseline	0	4673	0	1327
Logistic Regression	2126	2547	249	1078
Random Forest	2287	2386	215	1112
XGBoost	1841	2832	147	1180

Kết quả tại Bảng 3.2 cho thấy Logistic Regression phát hiện đúng 1.078 trong tổng số 1.327 khách hàng vỡ nợ, nhưng vẫn bỏ sót 249 trường hợp. Random Forest giảm số False Negative xuống 215 và đồng thời có số False Positive thấp hơn Logistic Regression. Điều này cho thấy Random Forest có xu hướng cân bằng hơn giữa khả năng phát hiện rủi ro và kiểm soát cảnh báo sai.

XGBoost có số False Negative thấp nhất, chỉ 147 trường hợp, tương ứng với Recall cao nhất trong các mô hình. Tuy nhiên, mô hình này cũng tạo ra 2.832 trường hợp False Positive, cao hơn Random Forest và Logistic Regression. Như vậy, XGBoost phù hợp hơn nếu mục tiêu là phát hiện tối đa khách hàng có nguy cơ vỡ nợ, trong khi Random Forest phù hợp hơn nếu cần cân bằng giữa phát hiện rủi ro và hạn chế cảnh báo sai.

Các tỷ lệ TNR, FPR, FNR và TPR được trình bày tại Phụ lục E nhằm giữ cho nội dung chính tập trung vào diễn giải trọng tâm.

3.1.4 Trả lời câu hỏi nghiên cứu 1

Câu hỏi nghiên cứu 1 đặt ra là: Các mô hình Machine Learning có cải thiện hiệu quả dự báo so với Logistic Regression trên bộ dữ liệu thẻ tín dụng hay không, và mô hình nào thể hiện phù hợp nhất theo các tiêu chí đánh giá?

Dựa trên kết quả thực nghiệm, có thể kết luận rằng các mô hình Machine Learning, cụ thể là Random Forest và XGBoost, cải thiện hiệu quả dự báo so với Logistic Regression trong phạm vi bộ dữ liệu nghiên cứu. Cả hai mô hình học máy đều đạt ROC-AUC, PR-AUC và F2-score cao hơn Logistic Regression. Điều

này cho thấy các mô hình dựa trên cây quyết định có khả năng khai thác tốt hơn các quan hệ phi tuyến và tương tác giữa các biến hành vi tín dụng.

Tuy nhiên, kết quả cũng cho thấy không nên khẳng định Random Forest vượt trội tuyệt đối so với XGBoost. Chênh lệch ROC-AUC giữa hai mô hình chỉ là 0,0003, trong khi XGBoost nhỉnh hơn nhẹ về Recall và F2-score. Ngược lại, Random Forest nhỉnh hơn về Precision, F1-score và KS Statistic. Vì vậy, kết luận phù hợp hơn là Random Forest và XGBoost có hiệu quả gần tương đương, nhưng phù hợp với các mục tiêu đánh giá khác nhau.

Trong nghiên cứu này, Random Forest được lựa chọn làm mô hình phân tích chính cho phần SHAP dựa trên hai căn cứ chính. Thứ nhất, Random Forest đạt ROC-AUC và KS Statistic cao nhất, lần lượt là 0,7730 và 0,4193. Kết quả này cho thấy mô hình có khả năng phân biệt rủi ro tổng thể tốt trên toàn bộ dải ngưỡng, phù hợp với mục tiêu xây dựng bảng hỗ trợ quyết định cần vận hành ổn định ở nhiều mức phân loại khác nhau. Thứ hai, Random Forest có số False Positive thấp hơn XGBoost, với 2.386 trường hợp so với 2.832 trường hợp. Điều này cho thấy mô hình kiểm soát cảnh báo sai tốt hơn, qua đó phù hợp với yêu cầu phân nhóm khách hàng và đưa ra khuyến nghị phê duyệt trong bảng hỗ trợ quyết định. Cả hai mô hình đều tương thích với TreeSHAP, do đó việc lựa chọn giữa hai mô hình không ảnh hưởng đến khả năng áp dụng phương pháp giải thích.

Tuy nhiên, việc lựa chọn Random Forest không hàm ý rằng mô hình này vượt trội tuyệt đối so với XGBoost. Kết quả thực nghiệm cho thấy XGBoost đạt Recall cao hơn, với 0,8892 so với 0,8380 của Random Forest, đồng thời F2-score cũng cao hơn nhẹ, lần lượt là 0,6330 và 0,6314. Vì vậy, trong trường hợp tổ chức tín dụng đặt trọng tâm vào việc hạn chế tối đa False Negative, XGBoost có thể là phương án phù hợp hơn. Từ các kết quả trên, RQ1 có thể được trả lời rằng các mô hình học máy giúp cải thiện hiệu quả dự báo so với Logistic Regression. Trong đó, Random Forest được lựa chọn làm mô hình phân tích chính do cân bằng tốt giữa khả năng phân biệt rủi ro tổng thể, kiểm soát False Positive và hỗ trợ giải


thích bằng SHAP. Dù vậy, XGBoost vẫn là một phương án thay thế đáng cân nhắc trong bối cảnh ưu tiên cao hơn cho Recall.

Tóm lại, RQ1 được trả lời như sau: Machine Learning có cải thiện hiệu quả dự báo so với Logistic Regression trong phạm vi bộ dữ liệu nghiên cứu; Random Forest và XGBoost là hai mô hình có hiệu quả cao nhất và gần tương đương nhau. Việc lựa chọn mô hình phân tích chính phụ thuộc vào mục tiêu quản trị: nếu ưu tiên khả năng phân biệt rủi ro tổng thể và kiểm soát cảnh báo sai (FP), Random Forest phù hợp hơn với $\text{ROC-AUC} = 0,7730$ và $\text{False Positive} = 2.386$; nếu ưu tiên phát hiện tối đa khách hàng vỡ nợ (Recall), XGBoost phù hợp hơn với $\text{Recall} = 0,8892$. Trong nghiên cứu này, Random Forest được chọn làm mô hình phân tích SHAP chính vì mục tiêu xây dựng decision table hỗ trợ phân nhóm rủi ro cần kiểm soát tốt cả hai loại sai lầm, không chỉ tối đa hóa Recall đơn thuần.

3.2 Phân tích các biến đóng góp vào dự báo theo SHAP values

Sau khi so sánh hiệu quả dự báo, nghiên cứu sử dụng SHAP để giải thích mô hình Random Forest. Việc lựa chọn Random Forest làm mô hình phân tích chính xuất phát từ kết quả tại mục 3.1: mô hình này đạt ROC-AUC và KS Statistic cao nhất, đồng thời có số False Positive thấp hơn XGBoost. Tuy nhiên, lựa chọn này không hàm ý Random Forest vượt trội tuyệt đối so với XGBoost, mà phản ánh sự cân bằng giữa hiệu quả dự báo và khả năng hỗ trợ giải thích.

3.2.1 Tầm quan trọng toàn cục của các biến



Hình 3.3: Top 20 biến quan trọng theo giá trị SHAP của mô hình Random Forest

Hình 3.3 trình bày 20 biến có giá trị mean absolute SHAP cao nhất của mô hình Random Forest. Kết quả cho thấy các biến liên quan đến lịch sử thanh toán và hành vi tín dụng giữ vai trò nổi bật nhất trong dự báo rủi ro vỡ nợ. Trong đó, late_count, PAY_0, PAY_2, avg_pay_amt và LIMIT_BAL là các biến có mức đóng góp lớn nhất vào dự báo của mô hình.

Biến late_count là biến nổi bật nhất. Biến này phản ánh số kỳ khách hàng có tình trạng thanh toán trễ hạn trong các tháng gần nhất. Việc biến này đứng đầu danh sách SHAP là hợp lý về mặt nghiệp vụ, vì lịch sử trễ hạn thường là tín hiệu trực tiếp phản ánh rủi ro tín dụng. Các biến PAY_0, PAY_2 và PAY_3 cũng thuộc


nhóm lịch sử thanh toán, tiếp tục cho thấy mô hình chủ yếu dựa vào hành vi trả nợ gần đây để dự báo khả năng vỡ nợ.

Bên cạnh đó, `avg_pay_amt` và `LIMIT_BAL` cũng xuất hiện trong nhóm biến quan trọng. `avg_pay_amt` phản ánh quy mô thanh toán trung bình của khách hàng, trong khi `LIMIT_BAL` thể hiện hạn mức tín dụng được cấp. Các biến này giúp mô hình đánh giá không chỉ lịch sử chậm thanh toán mà còn cả năng lực và hành vi thanh toán thực tế của khách hàng.

Một điểm đáng chú ý là các biến nhân khẩu học như giới tính, tình trạng hôn nhân hoặc trình độ học vấn không nằm trong nhóm biến quan trọng nhất. Điều này cho thấy mô hình dự báo chủ yếu dựa vào các tín hiệu hành vi tài chính hơn là đặc điểm nhân khẩu học tĩnh. Đây là kết quả phù hợp với logic quản trị rủi ro tín dụng, vì các tín hiệu hành vi thường có ý nghĩa nghiệp vụ trực tiếp hơn trong đánh giá khả năng trả nợ.

Cần nhấn mạnh rằng SHAP chỉ phản ánh mức đóng góp của biến vào dự báo của mô hình. Kết quả này không chứng minh quan hệ nhân quả giữa các biến đầu vào và trạng thái vỡ nợ. Vì vậy, trong nghiên cứu này, các biến quan trọng theo SHAP được hiểu là các tín hiệu dự báo quan trọng, không phải nguyên nhân trực tiếp gây ra vỡ nợ.

3.2.2 Hướng đóng góp của các biến qua SHAP summary plot



Hình 3.4: SHAP summary plot của mô hình Random Forest

Nếu biểu đồ SHAP bar plot cho biết biến nào quan trọng nhất, thì SHAP summary plot giúp xem xét thêm hướng đóng góp của từng biến. Mỗi điểm trên biểu đồ đại diện cho một quan sát, trong đó vị trí theo trục ngang phản ánh giá trị SHAP, còn màu sắc thể hiện giá trị của biến đầu vào.

Kết quả cho thấy các biến liên quan đến lịch sử thanh toán như late_count, PAY_0 và PAY_2 có vai trò đặc biệt quan trọng. Những giá trị cao của các biến này thường có xu hướng đẩy dự báo về phía xác suất vỡ nợ cao hơn. Điều này phù hợp với logic tín dụng: khách hàng có nhiều kỳ trễ hạn hoặc trạng thái thanh toán xấu trong các tháng gần nhất thường có nguy cơ vỡ nợ cao hơn.

Đối với avg_pay_amt, hướng đóng góp có thể khác nhau tùy theo bối cảnh của từng khách hàng. Trong nhiều trường hợp, giá trị thanh toán trung bình cao

có thể góp phần làm giảm xác suất vỡ nợ dự báo, vì nó phản ánh khả năng thực hiện nghĩa vụ thanh toán tốt hơn. Tuy nhiên, biến này không nên được diễn giải tách rời, mà cần xem xét cùng với dư nợ, hạn mức tín dụng và lịch sử thanh toán.

Biến LIMIT_BAL cũng có vai trò đáng chú ý. Hạn mức tín dụng cao không nhất thiết luôn làm giảm hoặc làm tăng rủi ro. Ý nghĩa của biến này phụ thuộc vào cách khách hàng sử dụng hạn mức, mức dư nợ và hành vi thanh toán. Vì vậy, SHAP giúp nhận diện vai trò dự báo của biến, nhưng việc diễn giải vẫn cần đặt trong bối cảnh nghiệp vụ tín dụng.

3.2.3 Diễn giải kinh tế của các yếu tố rủi ro chính

Từ kết quả SHAP, có thể chia các biến quan trọng thành ba nhóm chính.

Thứ nhất là nhóm lịch sử thanh toán, bao gồm late_count, PAY_0, PAY_2 và PAY_3. Đây là nhóm biến có ý nghĩa nghiệp vụ trực tiếp nhất, vì phản ánh mức độ trễ hạn của khách hàng trong các kỳ gần nhất. Việc các biến này có đóng góp lớn cho thấy mô hình dự báo chủ yếu dựa vào hành vi trả nợ gần đây.

Thứ hai là nhóm hành vi thanh toán, bao gồm avg_pay_amt và pay_ratio. Nếu khách hàng duy trì mức thanh toán tương đối tốt so với dư nợ, mô hình có thể xem đây là tín hiệu làm giảm rủi ro. Ngược lại, mức thanh toán thấp trong bối cảnh dư nợ cao có thể là dấu hiệu của áp lực tài chính.

Thứ ba là nhóm quy mô tín dụng và mức sử dụng hạn mức, bao gồm LIMIT_BAL, avg_bill_amt và util_rate. Các biến này giúp mô hình đánh giá mức độ sử dụng tín dụng của khách hàng. Tuy nhiên, nhóm biến này cần được diễn giải thận trọng, vì cùng một mức dư nợ có thể có ý nghĩa khác nhau đối với khách hàng có hạn mức tín dụng khác nhau.

Nhìn chung, kết quả SHAP cho thấy mô hình chủ yếu dựa vào hành vi tín dụng và lịch sử thanh toán gần đây. Đây là kết quả phù hợp với mục tiêu nghiên cứu, vì các biến hành vi thường có giá trị giải thích cao hơn trong bài toán dự báo rủi ro vỡ nợ so với các đặc điểm nhân khẩu học.

3.2.4 Trả lời câu hỏi nghiên cứu 2

Câu hỏi nghiên cứu 2 đặt ra là: Những biến nào có đóng góp quan trọng nhất vào dự báo rủi ro vỡ nợ của khách hàng cá nhân khi được phân tích thông qua SHAP values?

Kết quả SHAP cho thấy các biến liên quan đến lịch sử thanh toán và hành vi tín dụng gần đây giữ vai trò nổi bật nhất. Cụ thể, `late_count`, `PAY_0`, `PAY_2`, `avg_pay_amt` và `LIMIT_BAL` là các biến có mức đóng góp lớn nhất vào dự báo của mô hình Random Forest. Trong đó, nhóm biến lịch sử thanh toán đóng vai trò trung tâm, phản ánh việc mô hình sử dụng mạnh các tín hiệu hành vi gần đây để dự báo rủi ro vỡ nợ.

Về hướng tác động, các giá trị cao của `late_count` và các biến PAY thường có xu hướng làm tăng dự báo rủi ro. Ngược lại, các biến liên quan đến thanh toán như `avg_pay_amt` có thể làm giảm rủi ro trong những trường hợp khách hàng duy trì khả năng thanh toán tốt. Tuy nhiên, các biến này cần được diễn giải trong mối quan hệ với dư nợ, hạn mức tín dụng và lịch sử trả nợ.

Tóm lại, RQ2 được trả lời như sau: các yếu tố ảnh hưởng mạnh nhất theo SHAP chủ yếu thuộc nhóm hành vi tín dụng, đặc biệt là lịch sử trễ hạn và thanh toán gần đây. Tuy nhiên, SHAP chỉ phản ánh đóng góp của biến vào dự báo của mô hình, không chứng minh quan hệ nhân quả.

3.3 Phân tích rủi ro và hỗ trợ quyết định tín dụng

Bên cạnh việc đánh giá hiệu suất dự báo, nghiên cứu hướng tới mục tiêu chuyển đầu ra của mô hình thành căn cứ hỗ trợ quyết định tín dụng. Trong thực tế, tổ chức tài chính không chỉ cần biết mô hình dự báo đúng hay sai, mà còn cần biết khách hàng thuộc nhóm rủi ro nào và vì sao mô hình đưa ra đánh giá đó.

Do đó, phần này sử dụng xác suất vỡ nợ dự báo của mô hình Random Forest để phân nhóm khách hàng thành ba mức rủi ro: Low Risk, Medium Risk và High Risk. Sau đó, nghiên cứu xây dựng bảng khuyến nghị quyết định tín dụng và kết hợp SHAP để giải thích kết quả ở cấp độ nhóm và cấp độ cá nhân.

3.3.1 Phân nhóm rủi ro dựa trên xác suất vỡ nợ dự báo

Ngưỡng phân nhóm rủi ro được xác định dựa trên hai căn cứ. Thứ nhất, ngưỡng rủi ro thấp được xác định ở mức 0,167 trong phạm vi thực nghiệm, nhằm tách nhóm khách hàng có điểm rủi ro tương đối thấp. Thứ hai, ngưỡng rủi ro cao được lấy từ ngưỡng tối ưu theo F2-score của mô hình Random Forest, tương ứng với 0,320. Từ hai ngưỡng này, khách hàng được chia thành ba nhóm: Low Risk, Medium Risk và High Risk.


Cần lưu ý rằng các giá trị PD trong phần này không được diễn giải như xác suất vỡ nợ tuyệt đối đã được hiệu chỉnh. Do mô hình chưa thực hiện calibration đầy đủ bằng các phương pháp như Platt Scaling hoặc Isotonic Regression, PD trong nghiên cứu được sử dụng chủ yếu như một điểm rủi ro tương đối để xếp hạng và phân nhóm khách hàng. Vì vậy, các ngưỡng 0,167 và 0,320 mang ý nghĩa thực nghiệm trong phạm vi bộ dữ liệu holdout, không phải ngưỡng chính sách tín dụng có thể áp dụng trực tiếp trong thực tế.

Bảng 3.3: Phân nhóm rủi ro trên tập kiểm tra holdout

Nhóm rủi ro	Low Risk	Medium Risk	High Risk
Khoảng PD	$PD < 0,167$	$0,167 \leq PD < 0,320$	$PD \geq 0,320$
Số khách hàng	380	2.122	3.498
PD trung bình	0,1406	0,2483	0,5395
PD trung vị	0,1442	0,2502	0,4825
Tỷ lệ vỡ nợ quan sát	0,0421	0,0938	0,3179

Các giá trị PD trong bảng là xác suất dự báo trực tiếp từ mô hình Random Forest và chưa được hiệu chỉnh bằng các phương pháp calibration như Platt Scaling hoặc Isotonic Regression. Vì vậy, PD trung bình khoảng 0,54 ở nhóm High Risk không nên được hiểu theo nghĩa tuyệt đối rằng đúng 54% khách hàng trong nhóm này sẽ vỡ nợ. Trong phạm vi nghiên cứu, PD chủ yếu được sử dụng như một điểm rủi ro tương đối để xếp hạng và phân nhóm khách hàng.

Kết quả tại Bảng 3.3 cho thấy tỷ lệ vỡ nợ quan sát tăng dần theo mức rủi ro dự báo. Nhóm Low Risk có tỷ lệ vỡ nợ quan sát là 4,21%, nhóm Medium Risk là 9,38%, trong khi nhóm High Risk đạt 31,79%. Điều này cho thấy xác suất dự báo của mô hình có khả năng phân tầng rủi ro tương đối rõ ràng.



Hình 3.5: Tỷ lệ vỡ nợ quan sát theo nhóm rủi ro

Hình 3.5 trực quan hóa sự khác biệt về tỷ lệ vỡ nợ quan sát giữa ba nhóm rủi ro. Việc tỷ lệ vỡ nợ tăng từ 4,21% ở nhóm Low Risk lên 31,79% ở nhóm High Risk cho thấy mô hình không chỉ tạo ra điểm số dự báo, mà còn có thể hỗ trợ phân loại khách hàng theo mức độ rủi ro thực tế. Đây là cơ sở quan trọng để chuyển kết quả mô hình thành công cụ hỗ trợ quyết định tín dụng.

3.3.2 Bảng hỗ trợ quyết định tín dụng theo nhóm rủi ro

Bảng hỗ trợ quyết định tín dụng trong nghiên cứu này mang tính minh họa phương pháp, không phải chính sách phê duyệt tín dụng chính thức. Mục tiêu của bảng là cho thấy cách kết quả dự báo và giải thích SHAP có thể được chuyển hóa thành thông tin hỗ trợ chuyên viên tín dụng trong quá trình thẩm định. Trong triển

khai thực tế, quyết định cuối cùng vẫn cần kết hợp thêm dữ liệu nội bộ, chính sách rủi ro, quy định pháp lý, năng lực trả nợ, tài sản bảo đảm và đánh giá của chuyên viên tín dụng.

Bảng 3.4: Bảng hỗ trợ quyết định tín dụng minh họa theo nhóm rủi ro

Nhóm rủi ro	Khoảng PD	Khuyến nghị	Căn cứ
Low Risk	$PD < 0,167$	Có thể xem xét phê duyệt nếu các điều kiện khác phù hợp	PD thấp, tỷ lệ vỡ nợ quan sát thấp
Medium Risk	$0,167 \leq PD < 0,320$	Xem xét thủ công hoặc yêu cầu bổ sung hồ sơ	PD nằm trong vùng không chắc chắn; cần bổ sung thông tin ngoài mô hình để phán quyết
High Risk	$PD \geq 0,320$	Chuyên thẩm định chuyên sâu hoặc cân nhắc từ chối nếu không đạt điều kiện bổ sung	PD vượt ngưỡng F2-optimized, tỷ lệ vỡ nợ quan sát cao

Do xác suất dự báo trong nghiên cứu chưa được hiệu chỉnh calibration đầy đủ, các khoảng PD trong bảng nên được diễn giải như khoảng điểm rủi ro tương đối. Vì vậy, bảng này có giá trị minh họa về mặt phương pháp và hỗ trợ diễn giải, hơn là một bộ quy tắc triển khai trực tiếp trong hoạt động cấp tín dụng.

Bảng 3.4 cho thấy mô hình có thể hỗ trợ quy trình ra quyết định tín dụng theo hướng phân tầng. Với nhóm Low Risk, tổ chức tín dụng có thể ưu tiên xử lý nhanh hoặc phê duyệt nếu các điều kiện khác phù hợp. Với nhóm Medium Risk, mô hình khuyến nghị xem xét thủ công vì đây là vùng rủi ro trung gian. Với nhóm High Risk, mô hình cảnh báo xác suất vỡ nợ cao, do đó hồ sơ nên được chuyển sang cấp thẩm định chặt chẽ hơn hoặc bị từ chối tùy chính sách tín dụng.

3.3.3 Giải thích nhóm rủi ro bằng SHAP


Để tăng tính minh bạch cho framework hỗ trợ quyết định, nghiên cứu tiếp tục phân tích SHAP theo nhóm rủi ro. Kết quả cho thấy các nhóm rủi ro khác nhau thường có cấu trúc đóng góp biến khác nhau.

Đối với nhóm Low Risk, các yếu tố làm giảm rủi ro thường liên quan đến lịch sử thanh toán ổn định, số kỳ trễ hạn thấp và mức thanh toán tương đối tốt. Điều này phù hợp với tỷ lệ vỡ nợ quan sát thấp của nhóm này.

Đối với nhóm Medium Risk, mô hình thường ghi nhận tín hiệu pha trộn giữa yếu tố làm tăng và làm giảm rủi ro. Đây là lý do nhóm này không nên được xử lý bằng quyết định tự động, mà cần kết hợp thêm thông tin ngoài mô hình như thu nhập, lịch sử tín dụng bên ngoài hoặc đánh giá của chuyên viên.

Đối với nhóm High Risk, các biến như `late_count`, `PAY_0`, `PAY_2`, `PAY_3` và một số biến liên quan đến dư nợ thường đóng góp mạnh vào việc làm tăng dự báo rủi ro. Điều này cho thấy mô hình không chỉ xếp khách hàng vào nhóm rủi ro cao, mà còn cung cấp căn cứ giải thích vì sao hồ sơ đó cần được xem xét kỹ hơn.

3.3.4 Minh họa giải thích cấp cá nhân: *waterfall plot*



Hình 3.6: Waterfall plot minh họa dự báo cho một hồ sơ khách hàng rủi ro cao

Hình 3.6 minh họa waterfall plot cho một hồ sơ khách hàng có mức rủi ro cao. Biểu đồ cho thấy các biến nào làm tăng hoặc làm giảm dự báo rủi ro đối với riêng hồ sơ được phân tích. Đây là hình thức giải thích cục bộ, giúp người sử dụng hiểu rõ hơn vì sao mô hình đưa ra một dự báo cụ thể.

Trong bối cảnh tín dụng, waterfall plot có ý nghĩa thực tiễn vì nó có thể hỗ trợ chuyên viên tín dụng kiểm tra lại các yếu tố chính dẫn đến xếp hạng rủi ro. Ví dụ, nếu các biến như `late_count`, `PAY_0` hoặc `PAY_3` làm tăng mạnh xác suất vỡ nợ dự báo, chuyên viên có thể xem xét kỹ hơn lịch sử thanh toán gần đây của khách hàng trước khi đưa ra quyết định cuối cùng.

Tuy nhiên, cần nhấn mạnh rằng waterfall plot không thay thế quy trình thẩm định. Biểu đồ chỉ cung cấp thông tin giải thích dựa trên mô hình, trong khi quyết định tín dụng thực tế vẫn cần kết hợp thêm các thông tin ngoài dữ liệu như thu nhập, tài sản bảo đảm, hồ sơ tín dụng bên ngoài và chính sách nội bộ của tổ chức.

3.3.5 Trả lời câu hỏi nghiên cứu 3

Câu hỏi nghiên cứu 3 đặt ra là: Việc kết hợp Machine Learning và Explainable AI có thể hỗ trợ ra quyết định tín dụng minh bạch như thế nào?

Kết quả nghiên cứu cho thấy việc kết hợp Machine Learning và Explainable AI có thể hỗ trợ quyết định tín dụng theo ba cách. Thứ nhất, mô hình dự báo cung cấp điểm rủi ro giúp xếp hạng và phân nhóm khách hàng. Thứ hai, việc phân nhóm Low Risk, Medium Risk và High Risk giúp chuyển đầu ra của mô hình thành thông tin dễ sử dụng hơn trong quy trình tín dụng. Thứ ba, SHAP cung cấp căn cứ giải thích cho cả nhóm rủi ro và từng hồ sơ khách hàng cụ thể.

Tuy nhiên, mô hình không nên được xem là công cụ thay thế hoàn toàn quyết định của con người. Kết quả mô hình phù hợp hơn với vai trò hỗ trợ ra quyết định, giúp chuẩn hóa bước sàng lọc ban đầu, nhận diện nhóm khách hàng rủi ro cao và cung cấp căn cứ giải trình minh bạch hơn cho chuyên viên tín dụng.

Tóm lại, RQ3 được trả lời như sau: framework ML + XAI có thể hỗ trợ quyết định tín dụng bằng cách kết hợp điểm rủi ro, phân nhóm khách hàng, bảng khuyến nghị và giải thích SHAP. Cách tiếp cận này giúp kết quả mô hình dễ diễn giải hơn, nhưng vẫn cần được sử dụng như công cụ hỗ trợ, không phải cơ chế phê duyệt tự động.

3.4 Thảo luận tổng hợp

3.4.1 So sánh với nghiên cứu trước trên bộ dữ liệu UCI

Kết quả của nghiên cứu phù hợp với xu hướng chung trong các nghiên cứu về chấm điểm tín dụng, theo đó các mô hình học máy, đặc biệt là mô hình dựa trên cây quyết định và ensemble, thường đạt hiệu quả dự báo cạnh tranh so với mô hình tuyến tính truyền thống. Trong nghiên cứu này, Random Forest và XGBoost đều đạt ROC-AUC cao hơn Logistic Regression, cho thấy lợi thế của các mô hình phi tuyến trong việc khai thác cấu trúc phức tạp của dữ liệu.

Tuy nhiên, mức cải thiện không quá lớn. Điều này cho thấy trong bộ dữ liệu UCI (Yeh & Lien, 2009), các tín hiệu dự báo chính có thể đã được phản ánh tương đối rõ qua các biến lịch sử thanh toán. Do đó, mặc dù mô hình học máy cải thiện hiệu suất, khoảng cách so với Logistic Regression không đến mức vượt trội tuyệt đối. Đây là điểm cần được trình bày thận trọng để tránh phóng đại kết quả.

Bảng so sánh chi tiết với các nghiên cứu trước được chuyển sang Phụ lục G nhằm giữ Chương 3 tập trung vào kết quả thực nghiệm chính.

3.4.2 Lựa chọn mô hình phân tích chính

Trong phạm vi nghiên cứu, Random Forest được lựa chọn làm mô hình phân tích chính cho SHAP. Căn cứ của lựa chọn này là Random Forest đạt ROC-AUC và KS Statistic cao nhất, đồng thời có số False Positive thấp hơn XGBoost. Điều này cho thấy Random Forest có mức cân bằng tương đối tốt giữa khả năng phân biệt tổng thể và việc hạn chế cảnh báo sai.

Tuy nhiên, lựa chọn này cần được hiểu đúng. Random Forest không vượt trội tuyệt đối so với XGBoost. XGBoost đạt Recall và F2-score cao hơn, nghĩa là mô hình này phù hợp hơn nếu tổ chức tín dụng ưu tiên giảm tối đa số khách hàng vỡ nợ bị bỏ sót. Đổi lại, XGBoost tạo ra số False Positive cao hơn, có thể làm tăng số lượng hồ sơ cần thẩm định bổ sung.

Do đó, nghiên cứu lựa chọn Random Forest làm mô hình đại diện để phân tích sâu, nhưng vẫn ghi nhận XGBoost là phương án thay thế đáng cân nhắc trong trường hợp mục tiêu quản trị ưu tiên Recall và F2-score.

3.4.3 Giới hạn khi diễn giải kết quả

Mặc dù kết quả thực nghiệm cho thấy các mô hình học máy có khả năng cải thiện hiệu quả dự báo so với Logistic Regression, các kết quả này cần được diễn giải trong phạm vi của bộ dữ liệu nghiên cứu. Bộ dữ liệu được sử dụng là dữ liệu thẻ tín dụng tại Đài Loan, do đó không nên suy rộng trực tiếp sang thị trường Việt Nam nếu chưa có bước kiểm định lại trên dữ liệu nội bộ phù hợp.

Bên cạnh đó, xác suất vỡ nợ dự báo trong nghiên cứu được sử dụng chủ yếu như điểm rủi ro tương đối để xếp hạng và phân nhóm khách hàng. Nghiên cứu có kiểm tra calibration diagnostic ở mức bổ sung, nhưng chưa thực hiện hiệu chỉnh xác suất chính thức. Vì vậy, các giá trị PD không nên được diễn giải như xác suất vỡ nợ tuyệt đối trong triển khai thực tế.

Cuối cùng, các giá trị SHAP chỉ phản ánh cách mô hình sử dụng các biến đầu vào để hình thành dự báo, không chứng minh quan hệ nhân quả. Các hạn chế này sẽ được tổng hợp lại trong Chương 4 cùng với hàm ý quản trị và hướng nghiên cứu tiếp theo.

3.5 Kết luận chương 3

Chương 3 đã trình bày kết quả thực nghiệm và thảo luận theo ba câu hỏi nghiên cứu. Đối với RQ1, kết quả cho thấy Random Forest và XGBoost đều cải thiện hiệu quả dự báo so với Logistic Regression trên các chỉ số chính như ROC-AUC, PR-AUC và F2-score. Tuy nhiên, chênh lệch giữa Random Forest và XGBoost là rất nhỏ, do đó nghiên cứu không kết luận Random Forest vượt trội tuyệt đối. Random Forest được lựa chọn làm mô hình phân tích chính vì cân bằng hơn giữa hiệu suất dự báo, KS Statistic và khả năng hỗ trợ giải thích.

Đối với RQ2, phân tích SHAP cho thấy các biến hành vi tín dụng và lịch sử thanh toán gần đây, đặc biệt là `late_count`, `PAY_0`, `PAY_2`, `avg_pay_amt` và `LIMIT_BAL`, có đóng góp lớn vào dự báo rủi ro vỡ nợ. Kết quả này phù hợp với logic tín dụng, nhưng chỉ nên được hiểu là đóng góp của biến vào dự báo của mô hình, không phải bằng chứng nhân quả.

Đối với RQ3, nghiên cứu đã minh họa cách chuyển hóa xác suất vỡ nợ dự báo thành phân nhóm rủi ro, bảng hỗ trợ quyết định và giải thích bằng SHAP. Cách tiếp cận này cho thấy Machine Learning kết hợp Explainable AI có thể hỗ trợ quyết định tín dụng theo hướng minh bạch hơn, nhưng vẫn cần được sử dụng như công cụ hỗ trợ, không thay thế hoàn toàn vai trò của chuyên viên tín dụng.

CHƯƠNG 4 KẾT LUẬN VÀ HÀM Ý QUẢN TRỊ

Trên cơ sở các kết quả thực nghiệm và thảo luận đã trình bày ở Chương 3, Chương 4 tập trung tổng hợp những kết luận chính của đề tài, đồng thời đề xuất một số hàm ý quản trị đối với hoạt động chấm điểm tín dụng và kiểm soát rủi ro tại các tổ chức tài chính.

Bên cạnh việc khẳng định mức độ hoàn thành các mục tiêu nghiên cứu và trả lời các câu hỏi nghiên cứu, chương này cũng chỉ ra những hàm ý quản trị quan trọng đối với việc xây dựng hệ thống chấm điểm tín dụng theo hướng vừa nâng cao độ chính xác dự báo vừa bảo đảm tính minh bạch. Đồng thời, chương cũng thừa nhận các hạn chế còn tồn tại của nghiên cứu và đề xuất một số hướng nghiên cứu tiếp theo nhằm hoàn thiện hơn cách tiếp cận đã sử dụng trong đề tài.

4.1 Kết luận chung

Khóa luận được thực hiện nhằm xây dựng và đánh giá một mô hình dự báo rủi ro vỡ nợ của khách hàng cá nhân trên dữ liệu thẻ tín dụng, đồng thời kết hợp Explainable AI để nâng cao khả năng giải thích của mô hình. Trên cơ sở bộ dữ liệu Default of Credit Card Clients Dataset, nghiên cứu đã triển khai quy trình phân tích gồm tiền xử lý dữ liệu, xây dựng đặc trưng, xử lý mất cân bằng lớp bằng SMOTE trong pipeline, huấn luyện và tối ưu các mô hình Logistic Regression, Random Forest và XGBoost, sau đó sử dụng SHAP để giải thích kết quả dự báo.

Kết quả thực nghiệm cho thấy các mô hình học máy, đặc biệt là Random Forest và XGBoost, đều cải thiện hiệu quả dự báo so với Logistic Regression và Dummy Classifier trên nhiều chỉ số đánh giá. Random Forest đạt ROC-AUC cao nhất, trong khi XGBoost có lợi thế hơn ở Recall, F2-score và khả năng phát hiện khách hàng vỡ nợ. Do chênh lệch giữa Random Forest và XGBoost không đủ lớn để khẳng định ưu thế tuyệt đối của một mô hình, nghiên cứu không kết luận Random Forest là mô hình vượt trội hoàn toàn. Thay vào đó, Random Forest được lựa chọn làm mô hình phân tích SHAP chính vì có hiệu suất phân biệt cạnh tranh, phù hợp với TreeSHAP và thuận tiện cho việc minh họa cơ chế giải thích của

nhóm mô hình dựa trên cây quyết định. Như đã thảo luận ở mục 3.4.2, XGBoost là lựa chọn phù hợp hơn khi ưu tiên Recall.

Kết quả SHAP cho thấy các biến liên quan đến lịch sử thanh toán và hành vi tín dụng gần đây, đặc biệt là `late_count`, `PAY_0`, `PAY_2`, `avg_pay_amt` và `LIMIT_BAL`, là những tín hiệu dự báo quan trọng nhất trong mô hình. Điều này phù hợp với logic nghiệp vụ tín dụng, vì hành vi trả nợ trong quá khứ thường phản ánh trực tiếp khả năng thực hiện nghĩa vụ tài chính của khách hàng. Tuy nhiên, kết quả SHAP chỉ phản ánh mức đóng góp của biến vào dự báo của mô hình, không chứng minh quan hệ nhân quả.

Bên cạnh mục tiêu dự báo, nghiên cứu còn cho thấy cách kết hợp Machine Learning và Explainable AI có thể hỗ trợ quá trình ra quyết định tín dụng theo hướng minh bạch hơn. Cụ thể, xác suất vỡ nợ dự báo được chuyển hóa thành ba nhóm rủi ro: Low Risk, Medium Risk và High Risk. Tỷ lệ vỡ nợ quan sát tăng từ 4,21% ở nhóm Low Risk lên 31,79% ở nhóm High Risk, cho thấy mô hình có khả năng phân tầng rủi ro tương đối rõ ràng. Khi kết hợp với decision table và waterfall plot, kết quả mô hình không chỉ cung cấp điểm số rủi ro mà còn hỗ trợ giải thích lý do xếp hạng đối với từng hồ sơ khách hàng.

Kết quả cho thấy quy trình ML + XAI có thể hỗ trợ sàng lọc ban đầu, phân nhóm rủi ro và cung cấp căn cứ giải thích cho từng hồ sơ tín dụng. Tuy nhiên, mô hình không nên được xem là công cụ thay thế hoàn toàn quyết định của con người, mà phù hợp hơn với vai trò hỗ trợ ra quyết định, giúp chuẩn hóa quy trình đánh giá ban đầu, nhận diện nhóm khách hàng rủi ro cao và cung cấp căn cứ giải trình minh bạch hơn cho cán bộ tín dụng.

4.2 Hàm ý quản trị

4.2.1 Hàm ý đối với xây dựng mô hình chấm điểm tín dụng

Kết quả nghiên cứu cho thấy các tổ chức tài chính có thể cân nhắc ứng dụng các mô hình học máy trong hệ thống chấm điểm tín dụng cá nhân, đặc biệt khi dữ liệu có nhiều biến hành vi và quan hệ phi tuyến. So với Logistic Regression,

Random Forest và XGBoost cho thấy khả năng cải thiện hiệu quả dự báo, nhất là trên các chỉ số liên quan đến nhận diện khách hàng có nguy cơ vỡ nợ.

Tuy nhiên, việc lựa chọn mô hình cần được đặt trong bối cảnh mục tiêu quản trị cụ thể. Nếu tổ chức tín dụng ưu tiên khả năng phân biệt tổng thể giữa khách hàng rủi ro cao và rủi ro thấp, Random Forest là một lựa chọn phù hợp do đạt ROC-AUC và KS Statistic cao nhất trong nghiên cứu. Ngược lại, nếu mục tiêu chính là giảm tối đa số khách hàng vỡ nợ bị bỏ sót, XGBoost là phương án đáng cân nhắc hơn nhờ Recall và F2-score cao hơn.

Điều này cho thấy trong thực tiễn, không nên lựa chọn mô hình chỉ dựa trên một chỉ số duy nhất. Các tổ chức tài chính cần xây dựng bộ tiêu chí đánh giá phù hợp với khẩu vị rủi ro, chi phí sai lầm và mục tiêu kinh doanh của mình. Đối với bài toán tín dụng, Accuracy không nên là chỉ số trung tâm, vì dữ liệu thường mất cân bằng và chi phí giữa hai loại sai lầm không đối xứng. Các chỉ số như Recall, F2-score, PR-AUC, ROC-AUC và KS nên được xem xét đồng thời.

4.2.2 Hàm ý đối với thiết lập ngưỡng ra quyết định

Một kết quả quan trọng của nghiên cứu là việc sử dụng ngưỡng phân loại tối ưu theo F2-score thay vì ngưỡng mặc định 0,5. Trong bối cảnh tín dụng, ngưỡng 0,5 không nhất thiết phù hợp vì chi phí bỏ sót khách hàng vỡ nợ thường cao hơn chi phí phân loại nhầm khách hàng tốt vào nhóm rủi ro. Việc tối ưu ngưỡng theo F2-score giúp mô hình ưu tiên phát hiện khách hàng có nguy cơ vỡ nợ, phù hợp hơn với mục tiêu kiểm soát rủi ro.

Từ góc độ quản trị, ngưỡng phân loại không nên được xem là một giá trị cố định, mà là một tham số vận hành cần được rà soát và điều chỉnh định kỳ theo khẩu vị rủi ro, điều kiện thị trường và mục tiêu tín dụng của từng thời kỳ. Tuy nhiên, việc điều chỉnh ngưỡng dựa trên PD chỉ có ý nghĩa khi xác suất dự báo của mô hình đã được kiểm định và hiệu chỉnh calibration, chẳng hạn bằng Platt Scaling hoặc Isotonic Regression. Nếu mô hình chưa được calibration, một giá trị $PD = 0,32$ không thể được hiểu trực tiếp là khách hàng có 32% khả năng vỡ nợ;

khi đó, việc sử dụng ngưỡng PD để ước lượng chi phí rủi ro hoặc ra quyết định vận hành có thể dẫn đến sai lệch.

Sau khi mô hình đã được hiệu chỉnh xác suất, ngưỡng phân loại có thể được điều chỉnh linh hoạt hơn theo bối cảnh kinh tế. Trong giai đoạn bất ổn hoặc khi tỷ lệ nợ xấu có xu hướng tăng, tổ chức tín dụng có thể áp dụng ngưỡng thận trọng hơn nhằm tăng khả năng nhận diện khách hàng rủi ro. Ngược lại, khi thị trường ổn định và mục tiêu mở rộng tín dụng được ưu tiên, ngưỡng có thể được nói lỏng trong phạm vi khẩu vị rủi ro cho phép. Mọi thay đổi về ngưỡng cần được ghi nhận trong chính sách tín dụng nội bộ, có cơ sở dữ liệu hỗ trợ và được phê duyệt bởi cấp có thẩm quyền.

Ngoài ra, việc phân nhóm khách hàng thành Low Risk, Medium Risk và High Risk có thể hỗ trợ quá trình ra quyết định theo hướng linh hoạt hơn so với phân loại nhị phân đơn giản. Nhóm Low Risk có thể được ưu tiên xử lý nhanh hoặc áp dụng chính sách tín dụng thuận lợi hơn. Nhóm Medium Risk nên được chuyển sang thẩm định thủ công hoặc yêu cầu bổ sung thông tin. Nhóm High Risk cần được kiểm tra kỹ hơn, áp dụng hạn mức thấp hơn, yêu cầu bảo đảm bổ sung hoặc từ chối tùy theo chính sách của tổ chức.

4.2.3 Hàm ý đối với minh bạch và giải trình mô hình

Một trong những rào cản lớn khi áp dụng Machine Learning trong tín dụng là tính “hộp đen” của mô hình. Kết quả nghiên cứu cho thấy SHAP có thể giúp giảm bớt hạn chế này bằng cách giải thích mức đóng góp của từng biến vào dự báo. Nhờ đó, mô hình không chỉ đưa ra xác suất vỡ nợ, mà còn cung cấp thông tin về các yếu tố chính ảnh hưởng đến dự báo.

Đối với cán bộ tín dụng, SHAP có thể hỗ trợ hiểu rõ vì sao một khách hàng bị xếp vào nhóm rủi ro cao. Ví dụ, nếu mô hình đánh giá rủi ro cao chủ yếu do late_count, PAY_0 hoặc PAY_2, cán bộ tín dụng có thể kiểm tra lại lịch sử thanh toán gần đây của khách hàng trước khi đưa ra quyết định cuối cùng. Điều này giúp kết quả mô hình trở nên dễ kiểm tra hơn, thay vì chỉ là một điểm số khó diễn giải.

Đối với bộ phận quản trị rủi ro và kiểm toán nội bộ, SHAP có thể hỗ trợ giám sát mô hình bằng cách xác định các biến đang đóng vai trò quan trọng trong dự báo. Nếu mô hình phụ thuộc quá nhiều vào một biến không ổn định hoặc nhạy cảm, tổ chức có thể xem xét điều chỉnh quy trình mô hình hóa, kiểm tra bias hoặc bổ sung ràng buộc quản trị phù hợp.

Tuy nhiên, cần nhấn mạnh rằng SHAP không chứng minh quan hệ nhân quả. Vì vậy, các giải thích từ SHAP nên được sử dụng như căn cứ hỗ trợ kiểm tra và diễn giải mô hình, không nên được xem là bằng chứng tuyệt đối rằng một biến nhất định gây ra vỡ nợ. Việc sử dụng SHAP cần đi kèm với hiểu biết nghiệp vụ và quy trình kiểm soát mô hình phù hợp.

4.2.4 Hàm ý đối với quy trình vận hành tín dụng

Kết quả nghiên cứu gợi ý rằng mô hình ML+XAI có thể được tích hợp vào quy trình tín dụng theo vai trò hỗ trợ ra quyết định. Thay vì thay thế hoàn toàn cán bộ tín dụng, mô hình có thể được sử dụng ở bước sàng lọc ban đầu để phân loại hồ sơ theo mức độ rủi ro. Cách tiếp cận này giúp tổ chức tài chính phân bổ nguồn lực thẩm định hiệu quả hơn.

Cụ thể, các hồ sơ thuộc nhóm Low Risk có thể được xử lý nhanh hơn nếu đáp ứng các điều kiện tối thiểu khác. Các hồ sơ thuộc nhóm Medium Risk nên được chuyển sang quy trình xem xét thủ công, vì đây là nhóm có mức độ không chắc chắn cao hơn. Các hồ sơ thuộc nhóm High Risk cần được đánh giá kỹ hơn, có thể yêu cầu thêm thông tin, áp dụng điều kiện tín dụng chặt chẽ hơn hoặc chuyển lên cấp phê duyệt cao hơn.

Việc kết hợp mô hình dự báo với decision table giúp chuẩn hóa quy trình đánh giá, giảm phụ thuộc vào phán đoán chủ quan và tăng tính nhất quán trong ra quyết định. Đồng thời, SHAP giúp bổ sung lớp giải thích cho từng hồ sơ, hỗ trợ cán bộ tín dụng hiểu rõ các yếu tố chính khiến mô hình đánh giá khách hàng là rủi ro cao hoặc thấp.

Tuy nhiên, để triển khai thực tế, mô hình cần được tích hợp trong một quy trình quản trị rõ ràng. Tổ chức tài chính cần quy định ai có quyền sử dụng kết quả

mô hình, trong trường hợp nào cán bộ tín dụng có thể override kết quả, cách lưu trữ giải thích mô hình, và cơ chế giám sát hiệu suất sau triển khai. Đây là điều kiện cần thiết để mô hình học máy được sử dụng một cách an toàn và có trách nhiệm trong môi trường tài chính.

4.3 Hạn chế của nghiên cứu

Mặc dù nghiên cứu đã xây dựng được quy trình dự báo và giải thích tương đối hoàn chỉnh, vẫn tồn tại một số hạn chế cần được nhìn nhận rõ.

Thứ nhất, bộ dữ liệu được sử dụng là Default of Credit Card Clients Dataset tại Đài Loan trong giai đoạn 2005–2006. Do đó, kết quả nghiên cứu có thể chưa phản ánh đầy đủ hành vi tín dụng hiện nay hoặc đặc điểm của thị trường Việt Nam. Các yếu tố như môi trường kinh tế, chính sách tín dụng, thói quen thanh toán và hệ thống thông tin tín dụng có thể khác biệt đáng kể giữa các quốc gia và thời kỳ. Vì vậy, khả năng khái quát hóa của mô hình sang bối cảnh Việt Nam cần được kiểm định thêm.

Thứ hai, dữ liệu nghiên cứu chủ yếu bao gồm thông tin thẻ tín dụng, lịch sử thanh toán và một số đặc điểm nhân khẩu học cơ bản. Nghiên cứu chưa tích hợp các nguồn dữ liệu khác như thu nhập, nghề nghiệp, lịch sử tín dụng từ trung tâm thông tin tín dụng, tài sản bảo đảm, quan hệ khách hàng hoặc dữ liệu giao dịch chi tiết. Trong thực tế, các tổ chức tài chính thường sử dụng nhiều nguồn dữ liệu đa dạng hơn để đánh giá rủi ro tín dụng.

Thứ ba, nghiên cứu đã sử dụng SMOTE để xử lý mất cân bằng lớp, nhưng cách tiếp cận này vẫn có giới hạn. Như đã lưu ý ở mục 2.4, việc áp dụng SMOTE sau One-Hot Encoding có thể tạo ra các điểm tổng hợp không hoàn toàn phản ánh cấu trúc tự nhiên của dữ liệu phân loại. Mặc dù SMOTE được đặt trong pipeline để hạn chế data leakage, các nghiên cứu tiếp theo có thể xem xét các phương pháp phù hợp hơn với dữ liệu hỗn hợp, chẳng hạn như SMOTE-NC hoặc các kỹ thuật xử lý mất cân bằng khác.

Thứ tư, trong phạm vi khóa luận này, việc hiệu chỉnh xác suất dự báo bằng các kỹ thuật calibration chưa được triển khai do nội dung này không phải là trọng

tâm chính của đề tài. Mục tiêu của nghiên cứu là ứng dụng mô hình học máy kết hợp XAI trên bộ dữ liệu thẻ tín dụng nhằm đánh giá khả năng dự báo rủi ro vỡ nợ và phân tích khả năng giải thích của mô hình thông qua các yếu tố ảnh hưởng đến kết quả dự báo. Vì vậy, PD trong nghiên cứu được sử dụng chủ yếu như một chỉ báo hỗ trợ phân nhóm và xếp hạng rủi ro tương đối. Việc hiệu chỉnh xác suất bằng các phương pháp calibration có thể được xem là một hướng mở rộng trong các nghiên cứu tiếp theo, đặc biệt khi mục tiêu là khai thác PD sâu hơn trong bối cảnh triển khai thực tế.

Thứ năm, nghiên cứu chưa đánh giá sâu khía cạnh fairness. Một số biến như giới tính, tình trạng hôn nhân hoặc trình độ học vấn có thể liên quan đến vấn đề công bằng trong tín dụng. Mặc dù các biến nhân khẩu học không phải là nhóm biến quan trọng nhất theo SHAP, việc triển khai mô hình trong thực tế vẫn cần kiểm tra xem mô hình có tạo ra kết quả bất lợi không cân xứng đối với một nhóm khách hàng cụ thể hay không.

Thứ sáu, SHAP được sử dụng để giải thích dự báo của mô hình nhưng không chứng minh quan hệ nhân quả. Các biến có giá trị SHAP cao chỉ cho thấy chúng có đóng góp lớn vào dự báo trong mô hình, không khẳng định rằng chúng trực tiếp gây ra vỡ nợ. Do đó, các diễn giải từ SHAP cần được hiểu là giải thích mô hình, không phải kết luận nhân quả về hành vi tín dụng.

Cuối cùng, decision table trong nghiên cứu dựa trên giả định chi phí False Negative cao gấp 5 lần False Positive. Đây là giả định thực nghiệm nhằm minh họa cách chuyển xác suất dự báo thành khuyến nghị quyết định tín dụng. Trong thực tế, tỷ lệ chi phí này cần được xác định dựa trên dữ liệu tổn thất thực tế, LGD (Loss Given Default - tỷ lệ tổn thất khi vỡ nợ), EAD (Exposure at Default - dư nợ tại thời điểm vỡ nợ), lợi nhuận kỳ vọng và khẩu vị rủi ro của từng tổ chức tài chính.

4.4 Hướng nghiên cứu tiếp theo

Từ những hạn chế nêu trên, có thể đề xuất một số hướng nghiên cứu tiếp theo nhằm hoàn thiện mô hình và tăng khả năng ứng dụng thực tiễn.

Thứ nhất, các nghiên cứu sau có thể kiểm định mô hình trên dữ liệu thực tế của các tổ chức tài chính tại Việt Nam. Điều này giúp đánh giá khả năng khái quát hóa của mô hình trong bối cảnh thị trường, hành vi khách hàng và chính sách tín dụng trong nước. Việc sử dụng dữ liệu nội bộ cũng cho phép bổ sung thêm các biến quan trọng như thu nhập, nghề nghiệp, lịch sử tín dụng, tài sản bảo đảm và hành vi giao dịch.

Thứ hai, cần nghiên cứu thêm các phương pháp hiệu chỉnh xác suất dự báo. Calibration là bước quan trọng nếu xác suất vỡ nợ được sử dụng trực tiếp trong định giá rủi ro, phân bổ hạn mức hoặc tính toán expected loss. Các phương pháp như Platt Scaling, Isotonic Regression hoặc calibration theo từng phân khúc khách hàng có thể được xem xét trong các nghiên cứu tiếp theo.

Thứ ba, các nghiên cứu sau nên đánh giá fairness của mô hình một cách có hệ thống. Việc kiểm tra các chỉ số như disparate impact, equal opportunity hoặc khác biệt về false positive rate và false negative rate giữa các nhóm khách hàng có thể giúp phát hiện và giảm thiểu thiên lệch trong mô hình tín dụng. Đây là yêu cầu quan trọng nếu mô hình được triển khai trong môi trường ra quyết định có tác động trực tiếp đến khách hàng.

Thứ tư, có thể mở rộng so sánh sang các mô hình và kỹ thuật khác. Ngoài Random Forest và XGBoost, các nghiên cứu tiếp theo có thể xem xét LightGBM, CatBoost, mô hình calibrated boosting hoặc các phương pháp ensemble kết hợp. Đối với dữ liệu hỗn hợp gồm biến số và biến phân loại, các kỹ thuật xử lý mất cân bằng như SMOTE-NC, undersampling có kiểm soát hoặc cost-sensitive learning cũng là hướng đáng nghiên cứu.

Thứ năm, cần phát triển framework ra quyết định dựa trên chi phí thực tế. Thay vì sử dụng giả định chi phí FN/FP cố định, các nghiên cứu sau có thể xây dựng cost matrix dựa trên tổn thất kỳ vọng, bao gồm xác suất vỡ nợ, dư nợ tại thời điểm vỡ nợ, tỷ lệ tổn thất khi vỡ nợ và lợi nhuận kỳ vọng từ khoản tín dụng. Cách tiếp cận này sẽ giúp decision table sát hơn với thực tiễn quản trị rủi ro.

Nghiên cứu đã thực hiện kiểm tra sơ bộ độ tin cậy của xác suất dự báo thông qua Brier Score và reliability diagram. Kết quả này chỉ đóng vai trò diagnostic nhằm đánh giá mức độ phù hợp giữa xác suất dự báo và tỷ lệ vỡ nợ quan sát, chưa phải là bước hiệu chỉnh xác suất hoàn chỉnh. Do đó, trong phạm vi khóa luận, PD nên được hiểu chủ yếu như điểm rủi ro tương đối phục vụ xếp hạng và phân nhóm khách hàng. Nếu sử dụng PD cho định giá rủi ro, tính toán expected loss hoặc thiết lập hạn mức tín dụng, mô hình cần được calibration bằng Platt Scaling hoặc Isotonic Regression trên validation set riêng.

Cuối cùng, nghiên cứu tiếp theo có thể đánh giá model drift theo thời gian. Trong môi trường tín dụng, hành vi khách hàng và điều kiện kinh tế có thể thay đổi, khiến hiệu suất mô hình suy giảm sau triển khai. Do đó, cần xây dựng cơ chế giám sát định kỳ, bao gồm theo dõi phân phối dữ liệu đầu vào, hiệu suất dự báo, calibration, tỷ lệ nợ xấu thực tế và sự thay đổi của các biến quan trọng theo SHAP.

4.5 Kết luận chương

Chương 4 đã tổng hợp các kết quả chính của khóa luận, đồng thời rút ra hàm ý quản trị, hạn chế và hướng nghiên cứu tiếp theo. Kết quả nghiên cứu cho thấy các mô hình học máy có thể cải thiện hiệu quả dự báo rủi ro vỡ nợ so với Logistic Regression, nhưng việc lựa chọn mô hình cần dựa trên mục tiêu quản trị cụ thể thay vì chỉ dựa vào một chỉ số duy nhất. Random Forest có lợi thế nhẹ về khả năng phân biệt tổng thể, trong khi XGBoost phù hợp hơn nếu ưu tiên phát hiện khách hàng vỡ nợ.

Bên cạnh đó, việc kết hợp SHAP giúp mô hình trở nên minh bạch hơn bằng cách chỉ ra các biến đóng góp chính vào dự báo. Các biến lịch sử thanh toán và hành vi tín dụng gần đây là những tín hiệu quan trọng nhất, phù hợp với logic nghiệp vụ tín dụng. Khi được kết hợp với phân nhóm rủi ro và decision table, mô hình có thể hỗ trợ quy trình ra quyết định tín dụng theo hướng có căn cứ và dễ giải trình hơn.

Tuy nhiên, kết quả nghiên cứu cần được hiểu trong phạm vi dữ liệu và giả định thực nghiệm. Để triển khai trong thực tế, mô hình cần được kiểm định thêm

trên dữ liệu nội bộ, hiệu chỉnh xác suất dự báo, đánh giá fairness, giám sát model drift và thiết kế cost matrix phù hợp với khẩu vị rủi ro của từng tổ chức tài chính. Do đó, đóng góp chính của khóa luận nằm ở việc đề xuất và minh họa một framework kết hợp giữa Machine Learning và Explainable AI cho bài toán dự báo rủi ro tín dụng cá nhân, thay vì khẳng định một mô hình duy nhất có thể áp dụng trực tiếp cho mọi bối cảnh.

TÀI LIỆU THAM KHẢO

- [1] OECD, "Digital Financial Services: Mainstreaming Privacy and Consumer Protection," 2020.
- [2] Basel Committee on Banking Supervision, "Principles for the Management of Credit Risk," 2000.
- [3] Hand, D. J. and Henley, W. E., "Statistical Classification Methods in Consumer Credit Scoring: A Review," *Journal of the Royal Statistical Society Series A: Statistics in Society*, vol. 160, pp. 523-541, 1997.
- [4] Thomas, Lyn C., *Consumer Credit Models: Pricing, Profit and Portfolios*, Oxford: Oxford University Press, 2009.
- [5] Lessmann, S., Baesens, B., Seow, H. V., Thomas, L. C., "Benchmarking state-of-the-art classification algorithms for credit scoring," *European Journal of Operational Research*, vol. 247, no. 1, p. 124–136., 2015.
- [6] Guidotti, R., Monreale, A., Ruggieri, S., Turini, F., Giannotti, F., & Pedreschi, D., "A survey of methods for explaining black box models.," *ACM Computing Surveys*, vol. 51, no. 5, p. 1–42, 2018.
- [7] Bussmann, N., Giudici, P., Marinelli, D., & Papenbrock, J., "Explainable machine learning in credit risk management," *Computational Economics*, vol. 57, p. 203–216, 2021.
- [8] Arrieta, A. B., et al., "Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI," *Information Fusion*, vol. 58, p. 82–115, 2020.
- [9] Scott M. Lundberg, Su-In Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems (NIPS/NeurIPS)*, 2017.

- [10] Marco Tulio Ribeiro, Sameer Singh, Carlos Guestrin, ""Why should I trust you?": Explaining the predictions of any classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, New York, NY, USA, 2016.
- [11] Yeh, I-Cheng and Lien, Che-hui, "The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients," *Expert Systems with Applications*, vol. 36, pp. 2473-2480, 2009.
- [12] Bielecki, Tomasz R.; Rutkowski, Marek, *Credit Risk: Modeling, Valuation and Hedging*, Berlin: Springer, 2004.
- [13] Nkusu, Mwanza, "Nonperforming Loans and Macrofinancial Vulnerabilities in Advanced Economies," 2011.
- [14] J. Bessis, *Risk Management in Banking*, Chichester, West Sussex: Wiley, 2015.
- [15] J. C. Hull, *Risk Management and Financial Institutions*, Hoboken, New Jersey: Wiley, 2018.
- [16] Basel Committee on Banking Supervision, "Basel III: Finalising post-crisis reforms," 2017.
- [17] Saunders, Anthony and Cornett, Marcia Millon, *Financial Institutions Management: A Risk Management Approach*, 9th ed., McGraw-Hill Education, 2019.
- [18] Thomas, Lyn C. and Edelman, David and Crook, Jonathan, *Credit Scoring and Its Applications*, 2nd ed., Philadelphia: Society for Industrial and Applied Mathematics, 2017.
- [19] Adadi. A, & Berrada. M, "Peeking inside the black-box: A survey on explainable artificial intelligence (XAI)," *IEEE Access*, vol. 6, pp. 52138 - 52160, 2018.

- [20] Molnar, Christoph, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2nd ed., 2022.
- [21] Breiman, Leo, "Random Forests," *Machine Learning*, vol. 45, no. 1, p. 5–32, 2001.
- [22] Chen, Tianqi and Guestrin, Carlos, "XGBoost: A Scalable Tree Boosting System," 2016.
- [23] Chawla, Nitesh V. and Bowyer, Kevin W. and Hall, Lawrence O. and Kegelmeyer, Philip W., "SMOTE: Synthetic Minority Over-sampling Technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321-357, 2002.
- [24] D. A. Miles, "A taxonomy of research gaps: Identifying and defining the seven research gaps," in *Doctoral Student Workshop: Finding Research Gaps – Research Methods and Strategies*, Dallas, Texas, USA, 2017.

PHỤ LỤC

PHỤ LỤC A. KIỂM ĐỊNH ĐỘ ỔN ĐỊNH HIỆU SUẤT MÔ HÌNH

Phụ lục này trình bày các kết quả kiểm tra bổ sung nhằm đánh giá độ ổn định của hiệu suất mô hình. Các kết quả này được sử dụng để hỗ trợ mục 3.1 của Chương 3, đặc biệt khi so sánh Random Forest, XGBoost và Logistic Regression.

A.1. Khoảng tin cậy bootstrap 95% cho ROC-AUC và PR-AUC

Bảng A.1: Khoảng tin cậy bootstrap 95% cho ROC-AUC và PR-AUC trên tập holdout

Mô hình	ROC-AUC	ROC-AUC 95% CI	PR-AUC	PR-AUC 95% CI
Random Forest	0,7730	[0,759; 0,788]	0,5491	[0,521; 0,577]
XGBoost	0,7727	[0,759; 0,787]	0,5492	[0,522; 0,579]
Logistic Regression	0,7436	[0,728; 0,760]	0,5039	[0,475; 0,535]
Dummy Baseline	0,5000	[0,500; 0,500]	0,2212	[0,211; 0,232]

Kết quả tại Bảng A.1 cho thấy Random Forest và XGBoost có khoảng tin cậy ROC-AUC gần như chồng lấn. Điều này cho thấy chênh lệch hiệu suất giữa hai mô hình là rất nhỏ. Ngược lại, Logistic Regression có ROC-AUC và PR-AUC thấp hơn hai mô hình học máy.

A.2. Bootstrap 95% CI cho chênh lệch ROC-AUC

Bảng A.2: Bootstrap 95% CI cho chênh lệch ROC-AUC giữa các mô hình

So sánh mô hình	Delta ROC-AUC	95% CI	Diễn giải
Random Forest – XGBoost	0,0003	[-0,0028; 0,0036]	Chưa khác biệt rõ
Random Forest – Logistic Regression	0,0293	[0,0200; 0,0389]	Random Forest cao hơn rõ
XGBoost – Logistic Regression	0,0290	[0,0192; 0,0386]	XGBoost cao hơn rõ
Random Forest – Dummy Baseline	0,2730	[0,2582; 0,2877]	Random Forest cao hơn rõ
XGBoost – Dummy Baseline	0,2727	[0,2578; 0,2870]	XGBoost cao hơn rõ
Logistic Regression – Dummy Baseline	0,2436	[0,2277; 0,2595]	Logistic Regression cao hơn rõ

Kết quả tại Bảng A.2 cho thấy chênh lệch ROC-AUC giữa Random Forest và XGBoost có khoảng tin cậy chứa 0. Vì vậy, nghiên cứu không kết luận Random

Forest vượt trội rõ rệt so với XGBoost. Ngược lại, cả Random Forest và XGBoost đều có chênh lệch ROC-AUC dương rõ ràng so với Logistic Regression.

PHỤ LỤC B. KIỂM TRA CALIBRATION CỦA XÁC SUẤT DỰ BÁO

Phụ lục này trình bày nội dung kiểm tra sơ bộ về calibration của mô hình. Mục đích của kiểm tra này là đánh giá mức độ phù hợp giữa xác suất vỡ nợ dự báo và tỷ lệ vỡ nợ quan sát.

Cần lưu ý rằng nội dung trong phụ lục này chỉ mang tính diagnostic, tức kiểm tra sơ bộ. Nghiên cứu chưa thực hiện hiệu chỉnh xác suất chính thức bằng các phương pháp như Platt Scaling hoặc Isotonic Regression. Vì vậy, các giá trị xác suất vỡ nợ dự báo trong khóa luận được sử dụng chủ yếu như điểm rủi ro tương đối, không được diễn giải như xác suất vỡ nợ tuyệt đối trong triển khai thực tế.

B.1. Brier Score

Brier Score được sử dụng để đo lường sai số bình phương trung bình giữa xác suất dự báo và nhãn thực tế. Giá trị Brier Score càng thấp cho thấy xác suất dự báo càng gần với kết quả quan sát. Tuy nhiên, trong phạm vi nghiên cứu này, Brier Score chỉ được sử dụng như một kiểm tra bổ sung về chất lượng xác suất dự báo, không phải bằng chứng cho thấy mô hình đã được calibration đầy đủ.

B.2. Reliability curve

Reliability curve so sánh xác suất vỡ nợ dự báo với tỷ lệ vỡ nợ quan sát trong từng nhóm xác suất. Nếu đường biểu diễn nằm gần đường chéo lý tưởng, mô hình có mức calibration tốt hơn. Nếu đường biểu diễn lệch xa đường chéo, xác suất dự báo có thể chưa phản ánh chính xác tỷ lệ vỡ nợ thực tế.

Kết quả kiểm tra calibration cho thấy cần thận trọng khi diễn giải xác suất vỡ nợ dự báo. Trong phạm vi khóa luận, xác suất dự báo được sử dụng chủ yếu để xếp hạng và phân nhóm rủi ro. Nếu áp dụng vào thực tế, mô hình cần được hiệu chỉnh xác suất và kiểm định lại trên dữ liệu nội bộ của tổ chức tín dụng.

PHỤ LỤC C. CÔNG THỨC XÂY DỰNG ĐẶC TRƯNG

Phụ lục này trình bày công thức tóm tắt của các đặc trưng hành vi được xây dựng từ nhóm biến dư nợ sao kê, số tiền thanh toán, hạn mức tín dụng và lịch sử thanh toán của khách hàng.

Biến mới	Công thức	Ý nghĩa
avg_bill_amt	$avg_bill_amt = \frac{\sum_{j=1}^6 BILL_AM T_j}{6}$	Dư nợ sao kê trung bình trong sáu kỳ
util_rate	$util_rate = \frac{avg_bill_amt}{LIMIT_BAL}$	Mức độ sử dụng hạn mức tín dụng
avg_pay_amt	$avg_pay_amt = \frac{\sum_{j=1}^6 PAY_AM T_j}{6}$	Số tiền thanh toán trung bình trong sáu kỳ
pay_ratio	$pay_ratio = \frac{avg_pay_amt}{avg_bill_amt + \varepsilon}$	Tỷ lệ thanh toán trung bình so với dư nợ sao kê trung bình
late_count	$late_count = \sum_{i \in \{0,2,3,4,5,6\}} I(PAY_i > 0)$	Số kỳ khách hàng bị trễ hạn

Trong đó, $i \in \{0,2,3,4,5,6\}$, tương ứng với các biến PAY_0, PAY_2, PAY_3, PAY_4, PAY_5, PAY_6. Ký hiệu $I(PAY_i > 0)$ là hàm chỉ báo, nhận giá trị 1 nếu khách hàng trễ hạn tại kỳ i , và nhận giá trị 0 nếu ngược lại. Hằng số ε được thêm vào mẫu số nhằm tránh lỗi chia cho 0.

PHỤ LỤC D. CÔNG THỨC SMOTE VÀ CÁC CHỈ SỐ ĐÁNH GIÁ

Phụ lục này trình bày công thức tóm tắt của SMOTE và các chỉ số đánh giá được sử dụng trong nghiên cứu. Nội dung này bổ sung cho mục 2.4 và mục 2.6 của Chương 2.

D.1. Công thức SMOTE

SMOTE được sử dụng nhằm sinh thêm các quan sát tổng hợp cho lớp thiểu số. Với một quan sát thuộc lớp thiểu số x_i và một láng giềng gần nhất x_{nn} , quan sát tổng hợp x_{new} được tạo theo công thức:

$$x_{new} = x_i + \lambda(x_{nn} - x_i)$$

Trong đó, λ là một số ngẫu nhiên trong khoảng từ 0 đến 1. Trong nghiên cứu này, SMOTE chỉ được áp dụng trên tập huấn luyện trong từng fold của kiểm định chéo, không áp dụng trên tập kiểm tra holdout.

D.2. Ma trận nhầm lẫn

Ký hiệu	Ý nghĩa
TP	Số khách hàng vỡ nợ được dự báo đúng là vỡ nợ
TN	Số khách hàng không vỡ nợ được dự báo đúng là không vỡ nợ
FP	Số khách hàng không vỡ nợ nhưng bị dự báo là vỡ nợ
FN	Số khách hàng vỡ nợ nhưng bị dự báo là không vỡ nợ

D.3. Các chỉ số đánh giá phân loại

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

$$F2 = \frac{5 \times Precision \times Recall}{4 \times Precision + Recall}$$

Trong bài toán dự báo vỡ nợ, F2-score phù hợp hơn F1-score khi mục tiêu là ưu tiên phát hiện khách hàng có nguy cơ vỡ nợ.

D.4. ROC-AUC, PR-AUC và KS Statistic

ROC-AUC đo lường khả năng phân biệt tổng thể giữa nhóm khách hàng vỡ nợ và không vỡ nợ trên nhiều ngưỡng phân loại khác nhau. PR-AUC đo diện tích dưới đường cong Precision–Recall và đặc biệt hữu ích trong bối cảnh dữ liệu mất cân bằng.

KS Statistic đo mức độ tách biệt lớn nhất giữa phân phối điểm rủi ro của nhóm vỡ nợ và nhóm không vỡ nợ.

$$KS = \max |TPR - FPR|$$

Trong đó, TPR là tỷ lệ phát hiện đúng nhóm vỡ nợ, còn FPR là tỷ lệ khách hàng không vỡ nợ bị dự báo nhầm là vỡ nợ.

PHỤ LỤC E. MA TRẬN NHẦM LẤN CHI TIẾT

Phụ lục này trình bày ma trận nhầm lẫn đầy đủ và các tỷ lệ liên quan nhằm bổ sung cho mục 3.1.3 của Chương 3.

E.1. Ma trận nhầm lẫn đầy đủ

Bảng E.1: Ma trận nhầm lẫn đầy đủ của các mô hình tại ngưỡng F2 tối ưu

Mô hình	True Negative	False Positive	False Negative	True Positive
Dummy Baseline	0	4673	0	1327
Logistic Regression	2126	2547	249	1078
Random Forest	2287	2386	215	1112
XGBoost	1841	2832	147	1180

Tập kiểm tra holdout gồm 6.000 quan sát, trong đó có 4.673 khách hàng không vỡ nợ và 1.327 khách hàng vỡ nợ. Kết quả cho thấy XGBoost có số False Negative thấp nhất, trong khi Random Forest có số False Positive thấp hơn XGBoost.

E.2. Tỷ lệ dự báo đúng và sai theo từng nhóm thực tế

Bảng E.2: Tỷ lệ dự báo đúng và sai theo từng nhóm thực tế

Mô hình	TNR / Specificity	FPR	FNR	TPR / Recall
Dummy Baseline	0,0000	1,0000	0,0000	1,0000
Logistic Regression	0,4550	0,5450	0,1876	0,8124
Random Forest	0,4894	0,5106	0,1620	0,8380
XGBoost	0,3940	0,6060	0,1108	0,8892

Kết quả tại Bảng E.2 cho thấy XGBoost có FNR thấp nhất, tức bỏ sót ít khách hàng vỡ nợ nhất. Tuy nhiên, XGBoost cũng có FPR cao nhất, cho thấy mô hình cảnh báo sai nhiều khách hàng không vỡ nợ hơn. Random Forest có TNR cao nhất trong các mô hình thực nghiệm, đồng thời duy trì FNR thấp hơn Logistic

Regression. Vì vậy, Random Forest thể hiện sự cân bằng hơn giữa phát hiện rủi ro và kiểm soát cảnh báo sai.

PHỤ LỤC F. CẤU HÌNH MÔ HÌNH VÀ THAM SỐ TỐI ƯU

Phụ lục này trình bày tóm tắt cấu hình mô hình và quá trình tối ưu siêu tham số được sử dụng trong nghiên cứu. Nội dung này bổ sung cho mục 2.5 của Chương 2.

Thành phần	Thiết lập
Phương pháp tuning	RandomizedSearchCV
Kiểm định chéo	StratifiedKFold 5 folds
Tiêu chí tối ưu chính	ROC-AUC
Xử lý mất cân bằng	SMOTE trong ImbPipeline
Tập đánh giá cuối cùng	Holdout 20%, gồm 6.000 quan sát
Các mô hình	Logistic Regression, Random Forest, XGBoost, Dummy Classifier

Các mô hình được tối ưu trong pipeline nhằm đảm bảo các bước tiền xử lý, xử lý mất cân bằng và huấn luyện mô hình chỉ sử dụng dữ liệu trong tập huấn luyện của từng fold. Việc trình bày cấu hình mô hình tại phụ lục giúp Chương 2 tập trung vào logic phương pháp chính, đồng thời vẫn bảo đảm khả năng kiểm tra và tái lập quy trình thực nghiệm.

PHỤ LỤC G. SO SÁNH VỚI NGHIÊN CỨU TRƯỚC

Phụ lục này trình bày bảng so sánh kết quả nghiên cứu với một số nghiên cứu trước trong lĩnh vực chấm điểm tín dụng. Nội dung này bổ sung cho mục 3.4.1 của Chương 3.

Bảng G.1: So sánh kết quả nghiên cứu này với một số nghiên cứu trước

Nghiên cứu	Dữ liệu	Trọng tâm nghiên cứu	Mô hình/phương pháp chính	Ghi chú so sánh
Yeh và Lien (2009)	Default of Credit Card Clients Dataset	So sánh các kỹ thuật học máy trong dự báo vỡ nợ	Logistic Regression, Decision Tree, Neural Network và	Là nghiên cứu gốc trên bộ dữ

			các mô hình phân loại khác	liệu UCI thể tín dụng
Lessmann và cộng sự (2015)	Nhiều bộ dữ liệu credit scoring	Benchmark các thuật toán phân loại trong credit scoring	Nhiều mô hình thống kê và Machine Learning	Cho thấy các mô hình học máy thường có hiệu quả cạnh tranh trong chấm điểm tín dụng
Lundberg và Lee (2017)	Nhiều bài toán ML	Đề xuất SHAP như phương pháp giải thích mô hình	SHAP/SHAPley values	Cung cấp nền tảng phương pháp cho phân giải thích mô hình
Bussmann và cộng sự (2021)	Credit risk management	Ứng dụng XAI trong quản trị rủi ro tín dụng	Explainable Machine Learning	Nhấn mạnh yêu cầu minh bạch và giải trình trong tín dụng
Nghiên cứu này	Default of Credit Card Clients Dataset	Kết hợp dự báo, tối ưu ngưỡng, SHAP và hồ	Logistic Regression, Random Forest, XGBoost, SHAP	Đóng góp nằm ở việc kết nối hiệu suất dự báo với giải

		trợ quyết định tín dụng		thích và decision table
--	--	----------------------------	--	-------------------------------

Kết quả so sánh cho thấy nghiên cứu này kế thừa hai hướng chính trong văn liệu: sử dụng Machine Learning để cải thiện dự báo rủi ro và sử dụng Explainable AI để tăng khả năng giải thích. Điểm khác biệt của khóa luận nằm ở việc kết nối hai hướng này với phân nhóm rủi ro và bảng hỗ trợ quyết định tín dụng, thay vì chỉ dừng ở so sánh hiệu suất mô hình hoặc trình bày SHAP như một phân tích bổ sung.